TU Dortmund

Fallstudien I

Project 1: Deskriptive Auswertung demographischer Daten

Lecturer:
Prof. Dr. Jörg Rahnenführer
M.Sc. Marieke Stolte
Dr. Franziska Kappenberg
Dr. Julia Duda

Autor*in: Ahmed Ghroubi

Gruppennummer: 7

Gruppenmitglieder: Akin Münüsoglu, Salim Abdelkader Boukriniaa, Charbel Sakr

28. Oktober 2024

Inhaltsverzeichnis

1 Einleitung **3**

2 Problemstellung **3**

3 Statistische Methoden **5**

3.1 Deskriptive Statistik 5

3.2 Grafische Darstellung 7

4 Statistische Auswertung **8**

4.1 Häufigkeitsverteilungen und Geschlechterunterschiede 9

4.2 Bivariate Zusammenhänge zwischen Fertilitätsrate und Lebenserwartung . 9

4.3 Vergleich der Lebenserwartung und Fertilitätsrate in den Subregionen . . . 10

4.4 Entwicklung von Lebenserwartung und Fertilitätsrate im Vergleich 2002 zu 2022 12

5 Zusammenfassung **13**

Literaturverzeichnis **14**

1 Einleitung

Die Lebenserwartung der Weltbevölkerung hat in den letzten Jahrzehnten einen bemerkenswerten Anstieg verzeichnet. Im Jahr 2002 lag die durchschnittliche Lebenserwartung weltweit bei 66,7 Jahren, während sie im Jahr 2022 auf 72,98 Jahre gestiegen ist (vgl. https://www.macrotrends.net/global-metrics/countries/wld/world/life-expectancy#:~:text=The%20life%20expectancy%20for%20World%20in%202022%20was%2072.98%20years,a%200.24%25%20increase%20from%202020). Dieser deutliche Zuwachs um mehr als sechs Jahre innerhalb von nur zwei Jahrzehnten hat das Interesse vieler Studien weltweit geweckt. Im Rahmen dieser Studie wird die Entwicklung der Lebenserwartung und Fertilitätsrate in 227 Ländern und Territorien für die Jahre 2002 und 2022 untersucht. Ziel ist es, die demographischen Merkmale dieser beiden Variablen zu analysieren, Unterschiede zwischen den Geschlechtern zu identifizieren sowie bivariate Zusammenhänge zu prüfen. Zudem wird ein regionaler Vergleich der Merkmale vorgenommen, um Unterschiede zwischen den Subregionen aufzuzeigen. Abschließend erfolgt eine Analyse der zeitlichen Veränderungen dieser Merkmale über den Zeitraum von 20 Jahren, um Trends und Entwicklungen zwischen 2002 und 2022 zu erfassen. Im 2. Kapitel wird das Datenmaterial beschrieben. Dabei werden der Ablauf der Studie und die erhobenen Variablen genauer erläutert und die Qualität der Daten beurteilt. Außerdem werden die inhaltlichen und statistischen Ziele dargelegt. Kapitel 3 werden die verwendeten Methoden aus der deskriptiven und explorativen Statistik erklärt. Es werden einige Grundbegriffe der Datenanalyse definiert und Verfahren zur Analyse der Verteilung der Lebenserwartung und Fertilitätsrate beschrieben. Zudem werden Methoden vorgestellt, um Unterschiede zwischen den Subregionen und Geschlechtern zu untersuchen. Im darauf folgenden Kapitel wird die Auswertung der Daten vorgenommen. Dabei wird deskriptiv untersucht, wie sich die Lebenserwartung und Fertilitätsrate zwischen den Jahren 2002 und 2022 entwickelt haben und ob Unterschiede zwischen den Geschlechtern sowie den Subregionen bestehen. Auch bivariate Zusammenhänge zwischen den Variablen werden geprüft.

Im letzten Kapitel werden die wichtigsten Ergebnisse zusammengefasst und diskutiert, und es wird ein Ausblick auf weitere Untersuchungsmöglichkeiten gegeben. Im Anhang befinden sich Grafiken und Tabellen zum Vergleich der verschiedenen demographischen Merkmale.

2 Problemstellung

Der vorliegende Datensatz stammt aus der International Data Base (IDB) des U.S. Census Bureau und umfasst demographische Informationen zur Lebenserwartung und Fertilitäts-

rate für 227 Länder und Territorien für die Jahre 2002 und 2022. Die Daten wurden durch staatliche Quellen wie Volkszählungen, Umfragen und Bevölkerungsregister erhoben und durch das U.S. Census Bureau aggregiert und geschätzt. Dabei handelt es sich um eine Vollerhebung, die alle international anerkannten Länder und Territorien mit einer Mindestbevölkerung von 5.000 Personen umfasst. Die Länder sind geografisch in Regionen und Subregionen eingeteilt, um eine detaillierte regionale Analyse zu ermöglichen.Die Bevölkerungsprognosen und -schätzungen, die in der International Data Base (IDB) des U.S. Census Bureau enthalten sind, basieren auf einer Vielzahl von Datenquellen aus der ganzen Welt. Dazu zählen Volkszählungen, Umfragen, administrative Aufzeichnungen und vitalstatistische Daten, die von nationalen Statistikämtern zur Verfügung gestellt werden. Die Schätzungen und Projektionen berücksichtigen dabei wichtige demographische Faktoren wie Fertilität, Sterblichkeit und internationale Migration. Um demographische Veränderungen, die durch Ereignisse wie Krankheiten, Konflikte und Naturkatastrophen ausgelöst werden, genau abzubilden, verwendet die IDB das Demographic Analysis and Population Projection System (DAPPS). Dieses System ermöglicht es, Bevölkerungsprognosen nach Altersgruppen und Kalenderjahren über einen Basiszeitraum hinaus zu erstellen. Die Daten in der IDB stellen somit eine wertvolle Grundlage für die Analyse von Bevölkerungsstrukturen und deren langfristige Entwicklung dar. Der Datensatz enthält mehrere Variablen: das Erhebungsjahr (Year), den Namen des Landes oder Territoriums (Country), die durchschnittliche Lebenserwartung für die Gesamtbevölkerung (Life_Expectancy_Overall), die Lebenserwartung für Männer (Life_Expect
ancy_Male) und Frauen (Life_Expectancy_Female) sowie die Fertilitätsrate (Total_Fert
ility_Rate), die die geschätzte Anzahl der Kinder angibt, die eine Frau während ihres Lebens zur Welt bringt. Außerdem sind Informationen über die geografische Subregion (Subregion) und die übergeordnete Region (Region) enthalten, zu der das Land gehört. Die Datenqualität ist insgesamt solide, es gibt jedoch einige fehlende Werte (NA), die berücksichtigt werden müssen. Im Jahr 2002 fehlen für sechs Länder Daten: Libyen, Puerto Rico, Südsudan, Sudan, Syrien und die Vereinigten Staaten. Im Jahr 2022 fehlen nur die Daten für die Vereinigten Staaten. Insgesamt sind 28 fehlende Werte im Datensatz vorhanden, hauptsächlich aus dem Jahr 2002 sowie zusätzlich für die USA im Jahr 2022. Die USA-Daten für 2002 und 2022 fehlen in der Internationalen Datenbank (IDB) des U.S. Census Bureau, da die U.S.-Daten separat verwaltet und veröffentlicht werden (Link der Länder und Regionen - International Database in Literaturverzeichnis) . Die Bevölkerungsprognosen für die USA basieren auf nationalen Quellen wie Volkszählungen und unterscheiden sich in Veröffentlichungszyklen und Darstellung von den internationalen Daten. Daher erscheinen die USA in bestimmten Jahren, wie 2002 und 2022, nicht in der IDB . Die Variablen Life_Expectancy_Overall, Life_Expectancy_Male, Life_Expectancy_Female und Total_Fertility_Rate sind verhältnisskaliert, während die Variablen Subregion und Region nominalskaliert sind.

Ziel dieses Projekts ist es, die Verteilung der Lebenserwartung und der Fertilitätsrate im Jahr 2022 zu untersuchen. Dabei sollen Unterschiede zwischen den Geschlechtern sowie zwischen den verschiedenen Subregionen analysiert werden. Darüber hinaus wird die zeitliche Entwicklung dieser Merkmale zwischen den Jahren 2002 und 2022 untersucht, um demographische Trends und Veränderungen zu identifizieren. Es werden sowohl deskriptive als auch explorative statistische Verfahren angewendet, um Zusammenhänge zwischen den Variablen zu erkennen und zu interpretieren.

3 Statistische Methoden

In diesem Kapitel werden die statistischen Verfahren und Methoden beschrieben, die für die deskriptive und explorative Analyse der demographischen Daten eingesetzt wurden. Dabei wird auf grundlegende Konzepte, Schätzverfahren und die Software zur Durchführung der Analysen eingegangen.

3.1 Deskriptive Statistik

Das **arithmetische Mittel** ist ein statistisches Maß, das den Durchschnittswert einer Datenreihe angibt. Es wird berechnet, indem man alle Werte der Datenreihe summiert und die Summe durch die Anzahl der Werte teilt.es misst die zentrale Tendenz einer Datenreihe und gibt an, wo sich der „Schwerpunkt“ der Werte befindet . Mathematisch lässt sich das arithmetische Mittel durch die folgende Formel ausdrücken (vlg. Fahrmeir et al. 2023,S.53 - S.55) :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

wobei $\bar{x}$ das arithmetische Mittel, x_i die einzelnen Werte und n die Anzahl der Werte ist .Das p**-Quantil** ist ein Wert in einer geordneten Datenreihe, der die Daten so unterteilt, dass ein bestimmter Anteil p (mit $0 < p < 1$) der Datenpunkte kleiner oder gleich diesem Wert ist. Es bietet eine Möglichkeit, die Daten in verschiedene Abschnitte zu unterteilen und eine präzise Position für eine bestimmte Prozentzahl der Werte anzugeben.

Um das p-Quantil x_p in einer geordneten Liste von n Datenpunkten zu finden, multipliziert man die Anzahl der Daten n mit dem gewünschten Anteil p.[1]

[1] Umformuliert aus der Quelle: „Einführung in die Statistik“ von Jürgen Lehn und Helmut Wegmann, Seite 16.

$$x_p = \begin{cases} x_{(np)} & \text{falls } np \text{ eine ganze Zahl ist} \\ x_{(\lfloor np \rfloor + 1)} & \text{wenn } np \text{ keine ganze Zahl ist} \end{cases}$$

Hierbei bezeichnet $\lfloor np \rfloor$ die Abrundung auf die nächstkleinere ganze Zahl, falls np keine ganze Zahl ist.

Einige spezielle Quantile sind das **erste Quartil** $x_{0.25}$, das 25% der Daten umfasst, und das **dritte Quartil** $x_{0.75}$, das 75% der Daten unterhalb dieses Punktes zusammenfasst.[2]

Der Unterschied zwischen diesen beiden Quartilen wird als **Quartilabstand** bezeichnet und ist definiert durch:

$$q = x_{0.75} - x_{0.25}$$

Der **Median** einer geordneten Datenreihe $x_1, x_2, \ldots, x_n$ ist ein Lagemaß, das die Daten in zwei gleich große Hälften teilt. Der Median ist der Wert, unterhalb dessen 50% der Daten liegen und oberhalb dessen ebenfalls 50% der Daten liegen. Er wird oft als der mittlere Wert einer Datenreihe bezeichnet und ist besonders nützlich, wenn die Daten asymmetrisch verteilt sind, da er weniger anfällig für Ausreißer ist als das arithmetische Mittel.

Zur Berechnung des Medians gibt es zwei Fälle, abhängig davon, ob die Anzahl der Datenpunkte n gerade oder ungerade ist:

$$x_{\text{med}} = \begin{cases} x_{(k)}, & \text{wenn } n \text{ ungerade, mit } k = \frac{n+1}{2} \\ \frac{1}{2}(x_{(n/2)} + x_{(n/2+1)}), & \text{wenn } n \text{ gerade} \end{cases}$$

Falls n eine ungerade Zahl ist, ist der Median einfach der Wert an der Position $k = \frac{n+1}{2}$ in der geordneten Liste der Datenpunkte[3]. Bei einer geraden Anzahl an Datenpunkten ist der Median der Durchschnitt der beiden mittleren Werte $x_{(n/2)}$ und $x_{(n/2+1)}$[4]. Der Median kann als Spezialfall des p-Quantils betrachtet werden, da er dem 0,5-Quantil entspricht. Der **Bravais-Pearson-Korrelationskoeffizient** ist ein Maß, das die Stärke und Richtung des linearen Zusammenhangs zwischen zwei metrischen Merkmalen X und Y beschreibt. Er wird auch als *empirischer Korrelationskoeffizient* bezeichnet. Die Berechnung dieses Koeffizienten erfolgt nach folgender Formel:

$$r = r_{XY} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

[2] Umformuliert aus der Quelle, Seite 16.

[3] Diese Definition folgt der Darstellung im Buch „Basiswissen Statistik: Kompaktkurs für Anwender aus Wirtschaft, Informatik und Technik“ von Ansgar Steland, Seite 24.

[4] Ebenfalls basierend auf der Definition aus dem Buch, Seite 24.

wobei x_i und y_i die einzelnen Beobachtungswerte der Merkmale X und Y sind, und $\bar{x}$ sowie $\bar{y}$ die Mittelwerte der Merkmale X und Y darstellen.[5] In dieser Formel steht der Zähler, $\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$, für die **empirische Kovarianz** zwischen X und Y(vlg. Fahrmeir et al. 2023,S.53 - S.137). Die Kovarianz misst, wie X und Y gemeinsam variieren. Ein positiver Wert deutet darauf hin, dass größere Werte von X tendenziell mit größeren Werten von Y einhergehen, während ein negativer Wert darauf hinweist, dass größere Werte von X mit kleineren Werten von Y verbunden sind. Der Nenner der Formel, $\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}$, enthält die **empirischen Standardabweichungen** der Merkmale X und Y. Diese sind definiert durch(vlg. Fahrmeir et al. 2023,S.53 - S.137):

$$\tilde{s}_X = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}, \quad \tilde{s}_Y = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

Die Standardabweichungen geben an, wie stark die Werte eines Merkmals um ihren Mittelwert streuen. Der Bravais-Pearson-Korrelationskoeffizient r kann Werte zwischen -1 und $+1$ annehmen(vlg. Fahrmeir et al. 2023,S.53 - S.138). Ein Wert von $+1$ zeigt einen perfekten positiven linearen Zusammenhang an, bei dem alle Punkte auf einer steigenden Geraden liegen. Ein Wert von -1 zeigt einen perfekten negativen linearen Zusammenhang an, bei dem alle Punkte auf einer fallenden Geraden liegen. Ein Wert von 0 bedeutet, dass es keinen linearen Zusammenhang zwischen den beiden Merkmalen gibt.

3.2 Grafische Darstellung

In diesem Kapitel werden die Grafiken vorgestellt, die mit den R-Bibliotheken dplyr und ggplot2 erstellt wurden. Hierbei spielt insbesondere die Funktion ggplot() eine zentrale Rolle, die zur Visualisierung der demographischen Daten verwendet wurde. Ein **Histogramm** ist eine Grafik, die die Häufigkeitsverteilung von Daten zeigt, indem diese in *Klassen* oder Intervalle eingeteilt werden. Jedes Intervall, dargestellt durch $[c_0, c_1], [c_1, c_2], \ldots,$ $[c_{k-1}, c_k]$, fasst eine bestimmte Anzahl von Werten zusammen und wird als Säule im Histogramm abgebildet.[6] Um falsche Eindrücke zu vermeiden, wird die Höhe jeder Säule so berechnet, dass sie proportional zur Klassenbreite $d_j = c_j - c_{j-1}$ ist. Dadurch wird sichergestellt, dass die Fläche der Säule die Häufigkeit des jeweiligen Intervalls korrekt darstellt. Die Fläche berechnet sich als Produkt von Breite und Höhe:

$$\text{Fläche} = \text{Breite} \times \text{Höhe}$$

[5] Diese Formulierung und die Formel stammen aus der Quelle „Basiswissen Statistik: Kompaktkurs für Anwender aus Wirtschaft, Informatik und Technik“ von Ansgar Steland, Seite 137.

[6] Die Definition und Einteilung in Klassen basieren auf Folie 41 von Jürgen Lehn und Helmut Wegmann.

wobei die Höhe durch f_j/d_j (absolute Häufigkeit) oder h_j/d_j (relative Häufigkeit) bestimmt wird.[7] Ein **Boxplot** ist ein Diagramm, das die Streuung und zentrale Tendenz von Daten veranschaulicht. Es zeigt den Median sowie die mittleren 50% der Daten, die als *Interquartilsabstand* (IQR) bezeichnet werden, durch eine Box an. Die untere und obere Grenze der Box stellen das erste und dritte Quartil dar, und eine Linie innerhalb der Box markiert den Median.[8]Von der Box gehen die sogenannten *Whiskers* oder „Fühler“ aus, die in der Regel bis zu 1,5-mal den Interquartilsabstand vom Median reichen. Punkte, die außerhalb dieser Grenzen liegen, werden als *Ausreißer* dargestellt und können durch Kreise oder Sterne gekennzeichnet sein, je nach Abstand zum Median.[9] Durch diese kompakte Darstellung ermöglicht der Boxplot eine schnelle Einschätzung der Verteilung und möglicher Ausreißer in den Daten. Ein **Scatterplot** ist eine grafische Darstellung, die die Beziehung zwischen zwei metrischen Merkmalen X und Y zeigt. Jeder Datenpunkt wird als Punkt im Koordinatensystem abgebildet, wobei seine Position durch die Werte von X und Y bestimmt wird.[10] Zur Analyse wird das Diagramm in vier Felder unterteilt, die durch die Mittelwerte $\bar{x}$ und $\bar{y}$ als Achsenkreuz entstehen:

- Punkte im linken oberen und rechten unteren Feld haben ein negatives Vorzeichen.
- Punkte im rechten oberen und linken unteren Feld haben ein positives Vorzeichen.[11]

Wenn die meisten Punkte in den positiven Feldern liegen, besteht ein positiver Zusammenhang (beide Werte steigen). Liegen sie überwiegend in den negativen Feldern, weist dies auf einen negativen Zusammenhang hin (ein Wert steigt, der andere fällt).

4 Statistische Auswertung

Als nächstes wird die statistische Auswertung durchgeführt. Alle Berechnungen und Grafiken wurden mit dem statistischen Programmpaket R Version 4.2.1 (2022-06-23 ucrt) erstellt. Zu Beginn wird die Häufigkeitsverteilung der Merkmale analysiert, wobei auch die Unterschiede zwischen den Geschlechtern betrachtet werden. Anschließend erfolgt die Untersuchung auf bivariate Zusammenhänge zwischen den Merkmalen, um mögliche Korrelationen zu identifizieren. Ein weiterer Analysefokus liegt auf dem Vergleich der Merkmale zwischen den verschiedenen Subregionen. Dabei wird überprüft, ob signifikante Unterschiede in der Lebenserwartung und Fertilitätsrate zwischen den Subregionen bestehen. Abschließend wird die zeitliche Entwicklung der Merkmale zwischen 2002 und 2022 analysiert, um festzustellen, wie sich die demographischen Merkmale über die letzten 20 Jahre verändert haben.

[7]Diese Berechnung basiert auf Folie 42 von Jürgen Lehn und Helmut Wegmann
[8]Grundlagen zum Boxplot basieren auf Folie 70.
[9]Definition und Funktion der Whiskers und Ausreißer stammen aus Folie 70.
[10]Einführung und Konzept basieren auf Folie 88.
[11]Einteilung der Felder und Vorzeichen basieren auf Folie 88.

4.1 Häufigkeitsverteilungen und Geschlechterunterschiede

Die Häufigkeitsverteilung der Lebenserwartung im Jahr 2022 wird in Form eines Histogramms dargestellt. Abbildung 1a zeigt die Verteilung für Männer, die zwischen 50 und 85,7 Jahren liegt, wobei der größte Teil der Werte zwischen 65 und 75 Jahren zu finden ist. Dies zeigt, dass die meisten Männer in diesem Bereich eine ähnliche Lebenserwartung haben. Die Verteilung ist leicht nach rechts verschoben, was bedeutet, dass es eine kleinere Gruppe von Männern mit besonders hoher Lebenserwartung gibt. Bei den Frauen (Abbildung 1b)hingegen liegt die Lebenserwartung tendenziell höher, was man daran erkennt, dass das Histogramm insgesamt nach rechts verschoben ist. Der Großteil der Lebenserwartung der Frauen liegt zwischen circa 75 und 85 Jahren, was zeigt, dass Frauen im Durchschnitt länger leben als Männer. Es gibt zudem weniger Frauen mit einer Lebenserwartung unter 65 Jahren. Der Schiefekoeffizient für Frauen beträgt -0,729 und ist damit etwas stärker negativ als der für Männer (-0,598). Das bedeutet, dass die Verteilung bei den Frauen eine leichte Neigung nach links hat, was auf eine etwas größere Anzahl an Frauen mit niedriger Lebenserwartung hinweisen könnte, verglichen mit den Männern.

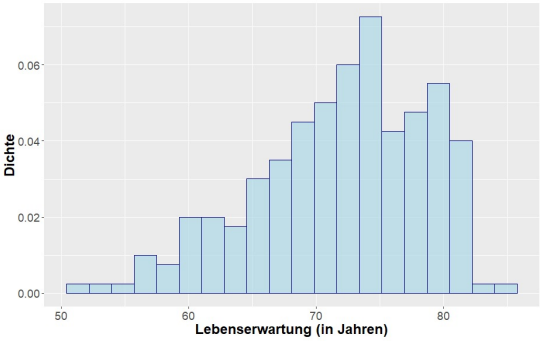

(a) Histogramm der Lebenserwartung von Männern (2022).

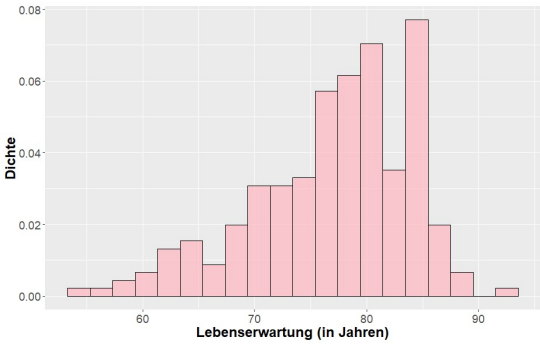

(b) Histogramm der Lebenserwartung von Frauen (2022).

Abbildung 1: Vergleich der Lebenserwartung von Männern und Frauen (2022).

4.2 Bivariate Zusammenhänge zwischen Fertilitätsrate und Lebenserwartung

In diesem Abschnitt wird der bivariate Zusammenhang zwischen Fertilitätsrate und Lebenserwartung im Jahr 2022 untersucht. Dabei wird analysiert, ob und wie stark diese beiden Merkmale miteinander in Beziehung stehen. Der vorliegende Scatterplot (Abbildung 2) untersucht den Zusammenhang zwischen Fertilitätsrate und Lebenserwartung im Jahr 2022. Auf der x-Achse ist die durchschnittliche Anzahl der Kinder pro Frau dargestellt, während die y-Achse die Lebenserwartung in Jahren abbildet. Es lässt sich beobachten, dass Länder mit einer höheren Fertilitätsrate – insbesondere im Bereich von etwa 3 bis knapp 7 Kindern pro Frau – tendenziell eine geringere Lebenserwartung aufweisen. Diese

Verteilung legt nahe, dass in Ländern mit hohen Geburtenraten die durchschnittliche Lebensspanne der Bevölkerung niedriger ist.Demgegenüber zeigt sich in Ländern mit einer Fertilitätsrate zwischen 1 und 3 eine deutlich höhere Lebenserwartung, die in den meisten Fällen über 75 Jahren liegt. Dieser Trend weist auf einen signifikanten negativen Zusammenhang zwischen der Fertilitätsrate und der Lebenserwartung hin, was darauf hindeutet, dass eine höhere Geburtenrate mit einer niedrigeren Lebenserwartung einhergeht. Dieser negative Zusammenhang wird durch den berechneten Pearson-Korrelationskoeffizienten von -0,767 bestätigt. Ein solcher Wert zeigt eine starke negative Korrelation und bestätigt die Beobachtung, dass die Lebenserwartung mit steigender Fertilitätsrate sinkt.

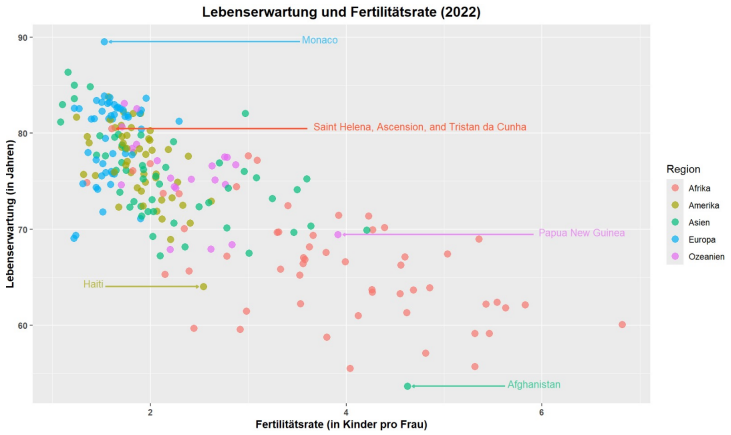

Abbildung 2: Zusammenhang zwischen Fertilitätsrate und Lebenserwartung weltweit im Jahr 2022

4.3 Vergleich der Lebenserwartung und Fertilitätsrate in den Subregionen

Die beiden Boxplots in Abbildung 3 veranschaulichen die Verteilung der Lebenserwartung und der Fertilitätsrate in verschiedenen Subregionen weltweit, wobei die Subregionen farblich auf der x-Achse nach den Hauptregionen (Afrika, Amerika, Asien, Europa und Ozeanien) kodiert sind. Bei der Analyse der Boxplots wurde der Durchschnitt der Lebenserwartung und Fertilitätsrate in den verschiedenen Subregionen untersucht.Bei der Lebenserwartung sind die höchsten Medianwerte in Regionen wie Westeuropa (82,4 Jahre), Australien/Neuseeland (82,8 Jahre) und Nordamerika (81,7 Jahre) zu beobachten. Insgesamt weist Europa durchgehend hohe Werte auf, wobei Westeuropa, Nordeuropa (82,0 Jahre) und Südeuropa (81,0 Jahre) nahe beieinanderliegen. Auch Ostasien zeigt mit einem Median von 82,1 Jahren hohe Werte, vergleichbar mit denen Europas und Australiens/Neuseelands. Diese Subregionen haben nicht nur hohe Medianwerte, sondern auch eine relativ geringe Streuung, was auf eine konstante Lebenserwartung innerhalb dieser Regionen hinweist. Afrika hingegen weist im Vergleich die niedrigsten Werte in der Le-

benserwartung auf. Subregionen wie Mittleres Afrika (63,3 Jahre) und Südliches Afrika (61,5 Jahre) haben die niedrigsten Medianwerte, und die Streuung ist hier ebenfalls groß, besonders in Nordafrika (Median: 74,4 Jahre) und Westafrika (63,7 Jahre). Ostafrika (67,2 Jahre) und Nordafrika zeigen höhere Medianwerte als die anderen afrikanischen Subregionen, jedoch bleiben sie deutlich unter dem Niveau von Europa, Australien/Neuseeland und Ostasien.In Asien zeigt sich eine starke Heterogenität: Ostasien erreicht mit einem Median von 82,1 Jahren eine der höchsten Lebenserwartungen weltweit, während Südasien und Südostasien niedrigere Werte aufweisen, mit Medianen von 72,4 bzw. 73,1 Jahren. Diese Unterschiede verdeutlichen, dass Asien sowohl Regionen mit sehr hoher als auch mit moderater Lebenserwartung umfasst.Bei der Fertilitätsrate zeigt sich ein umgekehrtes Muster. Afrika sind die Fertilitätsraten in den Subregionen Westafrika (4,23 Kinder pro Frau) und Mittleres Afrika (4,26) am höchsten. Diese Regionen weisen nicht nur hohe Medianwerte auf, sondern auch eine relativ große Streuung, insbesondere in Westafrika. Nordafrika und Ostafrika zeigen im Vergleich zu anderen afrikanischen Subregionen geringfügig niedrigere Werte, bleiben jedoch deutlich über dem Niveau anderer Weltregionen. Europa hat durchweg die niedrigsten Fertilitätsraten. Westeuropa (1,61), Südeuropa (1,48) und Osteuropa (1,51) liegen alle unter dem Ersatzniveau von 2,1 Kindern pro Frau, was auf eine sehr niedrige Geburtenrate hindeutet. Auch Nordeuropa zeigt mit einem Median von 1,66 eine niedrige Fertilitätsrate. Nordamerika und Ostasien (1,30) sind mit Medianwerten unter 2 Kindern pro Frau ebenfalls in dieser Kategorie, wobei Ostasien den niedrigsten Medianwert aller Subregionen aufweist.Die Regionen der Amerikas, insbesondere Südamerika (2,01) und Zentralamerika (2,08), zeigen mittlere Werte, die sich im Bereich von etwa 2 Kindern pro Frau bewegen, was sie zwischen den sehr niedrigen europäischen und ostasiatischen Werten und den sehr hohen Werten in Afrika positioniert. In Ozeanien ist eine moderate Fertilitätsrate zu sehen, wobei Mikronesien (2,62) und Melanesien (2,66) etwas höhere Werte aufweisen als andere Subregionen in dieser Region.

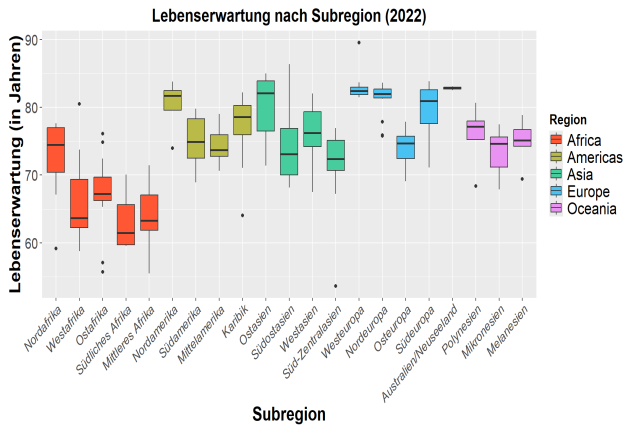

(a) Lebenserwartung in verschiedenen Subregionen (2022)

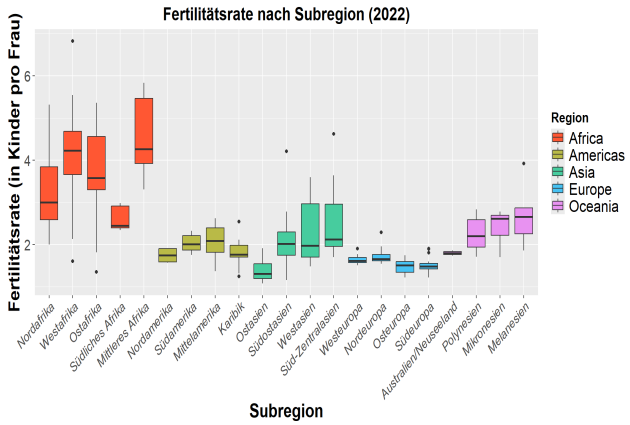

(b) Fertilitätsrate in verschiedenen Subregionen (2022)

Abbildung 3: Boxplots von Lebenserwartung und Fertilitätsrate in verschiedenen Subregionen

4.4 Entwicklung von Lebenserwartung und Fertilitätsrate im Vergleich 2002 zu 2022

Die Scatterplots in Abbildung 4 zeigen eine starke negative Korrelation zwischen Fertilitätsrate und Lebenserwartung, mit einem Pearson-Wert von -0,82 im Jahr 2002 und -0,77 im Jahr 2022, was bedeutet, dass höhere Fertilitätsraten oft mit geringerer Lebenserwartung einhergehen. Europa und Nordamerika haben durchweg niedrige Fertilitätsraten und hohe Lebenserwartungen, wobei Monaco mit fast 90 Jahren Lebenserwartung und sehr niedriger Fertilitätsrate als Extrempunkt hervorsticht. In Afrika zeigen Regionen wie West- und Zentralafrika hohe Fertilitätsraten und niedrige Lebenserwartungen, während Saint Helena, Ascension und Tristan da Cunha als Ausreißer eine moderate Lebenserwartung bei niedriger Fertilitätsrate aufweisen. In Asien ist Afghanistan ein bemerkenswerter Fall mit einer sehr hohen Fertilitätsrate und niedriger Lebenserwartung in beiden Jahren. Amerika liegt meist im mittleren Bereich, mit Haiti als Ausreißer, das 2002 eine niedrige Lebenserwartung und hohe Fertilitätsrate zeigte, 2022 jedoch eine leichte Verbesserung der Lebenserwartung aufweist. Ozeanien bleibt relativ stabil, mit Papua-Neuguinea als Beispiel für eine mittlere Lebenserwartung und höhere Fertilitätsrate. Im Jahr 2022 zeigen fast alle Länder eine Verschiebung nach links oben im Diagramm, was auf eine generelle Senkung der Fertilitätsrate und eine Erhöhung der Lebenserwartung hindeutet. Diese regionalen Unterschiede verdeutlichen den globalen Trend: Je höher die Lebenserwartung, desto niedriger die Fertilitätsrate.

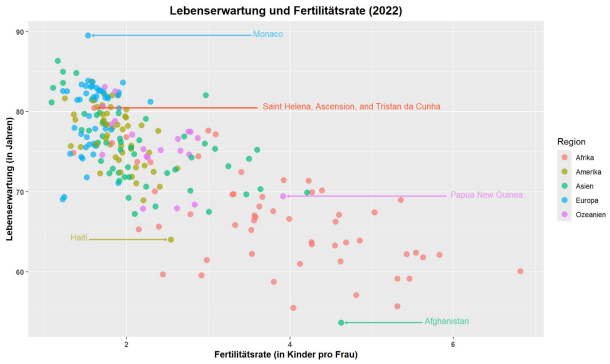

(a) Histogramm der Lebenserwartung von Männern (2022).

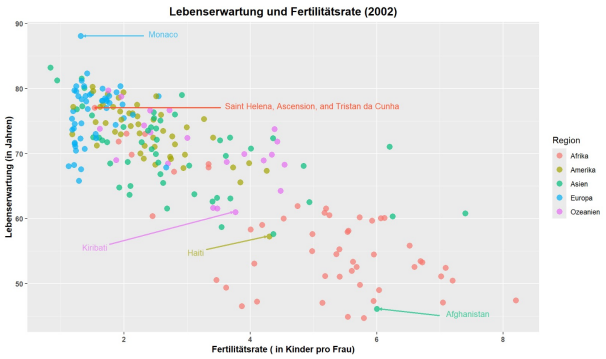

(b) Histogramm der Lebenserwartung von Frauen (2022).

Abbildung 4: Unterschiede in der Lebenserwartung zwischen Männern und Frauen für das Jahr 2022

5 Zusammenfassung

Im Rahmen dieses Projekts wurde die Fragestellung untersucht, welche demographischen Zusammenhänge zwischen Lebenserwartung und Fertilitätsrate in verschiedenen Ländern und Subregionen bestehen und wie sich diese Merkmale in den letzten 20 Jahren entwickelt haben. Die Daten stammen aus der International Data Base (IDB) des U.S. Census Bureau und enthalten Informationen zu 227 Ländern und Territorien, die aus staatlichen Quellen wie Volkszählungen, Umfragen und Bevölkerungsregistern aggregiert wurden. Der Datensatz umfasst alle international anerkannten Länder und Regionen mit einer Mindestbevölkerung von 5.000 Personen und bietet dadurch eine umfassende Grundlage für die Analyse globaler demographischer Trends.

Die wichtigsten Ergebnisse zeigen, dass die Lebenserwartung bei Frauen durchschnittlich höher ist als bei Männern und dass ein starker negativer Zusammenhang zwischen Fertilitätsrate und Lebenserwartung besteht, was bedeutet, dass Länder mit niedrigeren Fertilitätsraten tendenziell eine höhere Lebenserwartung aufweisen. In den letzten 20 Jahren hat sich dieser Trend weltweit fortgesetzt, mit sinkenden Geburtenraten und steigenden Lebenserwartungen. Regionale Unterschiede bleiben jedoch ausgeprägt: Europa, Nordamerika und Australien zeigen die höchsten Lebenserwartungen und niedrigsten Geburtenraten, während afrikanische Subregionen nach wie vor höhere Fertilitätsraten und geringere Lebenserwartungen aufweisen. Diese Ergebnisse wurden mittels bivariater Korrelationsanalysen und Pearson-Korrelationskoeffizienten überprüft, was auf robuste Zusammenhänge hindeutet.

Als Ausblick eröffnet diese Studie das Potenzial, die Lebenserwartung in Verbindung mit zusätzlichen Faktoren wie wirtschaftlichem Wohlstand, Bildungsstand und Gesundheitsversorgung weiter zu untersuchen. Eine solche multidimensionale Analyse könnte helfen, ein tieferes Verständnis der Faktoren zu gewinnen, die die Lebenserwartung weltweit beeinflussen, und könnte zu spezifischeren Handlungsempfehlungen für die Verbesserung der Lebensqualität führen. Diese Perspektive wäre besonders wertvoll, um auf den bestehenden globalen Disparitäten aufzubauen und Maßnahmen zur Förderung der Lebenserwartung in benachteiligten Regionen gezielt zu unterstützen.

Literaturverzeichnis

- Götze, W., Deutschmann, C., & Link, H. (2010). *Statistik: Lehr- und Übungsbuch mit Beispielen aus der Tourismus- und Verkehrswirtschaft.*
- Steland, A. *Basiswissen Statistik: Kompaktkurs für Anwender aus Wirtschaft, Informatik und Technik.*
- Dormann, C. F. *Parametrische Statistik: Eine Einführung.*
- Kuckartz, U., Rädiker, S., Ebert, T., & Schehl, J. (2010). *Statistik: Eine verständliche Einführung.*
- Definitionen der Variablen:
  URL: `https://www.census.gov/programs-surveys/international-programs/about/glossary.html` (besucht am 20.10.2024).
- Für weitere Details bezüglich der Datenerhebung:
  URL: `https://www.census.gov/programs-surveys/international-programs/about/idb.html` (besucht am 19.10.2024).
- Länder und Regionen - International Database (IDB):
  URL: `https://www.census.gov/programs-surveys/international-programs/about/idb/countries-and-areas.html` (besucht am 23.10.2024).