

„TU DORTMUND

FALLSTUDIEN I

Projekt 4: Kontingenztafelanalyse des olympischen Medaillenspiegels

Dozenten:

Prof. Dr. Jörg Rahnenführer

M.Sc. Marieke Stolte

Dr. Franziska Kappenberg

Dr. Julia Duda

Autor*in: Ahmed Ghroubi

Gruppennummer: 7

Gruppenmitglieder: Akin Münüsoglu, Salim Abdelkader
Boukrinia, Charbel Sakr

9. Januar 2025

Inhaltsverzeichnis

Inhaltsverzeichnis

1	Einleitung	1
2	Problemstellung	1
2.1	Datenmaterial	2
2.2	Zielsetzung	2
3	Statistische Methoden	3
3.1	Kontingenztafel	3
3.2	Chi-Quadrat-Test	4
3.3	Exakter Test nach Fisher	5
4	Statistische Auswertung	6
4.1	Deskriptive Analyse	7
4.2	Abhängigkeit zwischen Sportart und Land in Bezug auf die Gesamtmedail- lenanzahl	8
4.3	Abhängigkeit zwischen Medaillenfarbe und Land innerhalb der Sportarten	8
4.4	Untersuchung der Abhängigkeit zwischen Medaillenfarbe und Sportart in- nerhalb der Länder	10
5	Zusammenfassung	12
	Literatur	14
	Anhang	15

1 Einleitung

Die Olympischen Spiele sind ein globales Ereignis, das Nationen aus aller Welt vereint und Spitzenleistungen in einer Vielzahl von Sportarten feiert (vgl. Statista, B. Zeppenfeld, 12.08.2024). Die 33. Olympischen Sommerspiele wurden vom 26. Juli bis 11. August 2024 ausgetragen, mit Paris als Hauptaustragungsort sowie weiteren Wettkampfstätten in Frankreich und Französisch-Polynesien. Aus 206 Ländern traten 11.119 Athletinnen und Athleten in 329 Wettkämpfen über 32 Sportarten an, um Medaillen zu gewinnen. Ziel dieses Projekts ist es, systematische Zusammenhänge in den Medaillendaten der Top-5-Nationen (USA, China, Japan, Australien und Frankreich) aufzudecken. Im Fokus stehen dabei Abhängigkeiten zwischen Sportarten und Ländern sowie die Verteilung der Medaillenfarben in unterschiedlichen Sportarten und Ländern. Grundlage der Analyse bildet ein Datensatz, der die Medaillenzahlen in vier Sportartgruppen (Kampfsport, Leichtathletik, Ballsportarten und Schwimmen) zusammenfasst. Die methodische Herangehensweise umfasst deskriptive und inferenzstatistische Verfahren, darunter Chi-Quadrat-Tests und exakte Fisher-Tests. Diese Tests dienen dazu, die statistische Signifikanz von Zusammenhängen zu bewerten und robuste Schlussfolgerungen zu ziehen. Die Ergebnisse der Olympischen Spiele 2024 zeigen eine signifikante Abhängigkeit zwischen Sportart und Land. Dabei dominierten die USA in Leichtathletik und Schwimmen, während Japan im Kampfsport herausragte. Es konnten jedoch im Jahr 2024 keine Abhängigkeiten zwischen Medaillenfarbe und Land oder Sportart festgestellt werden. Bonferroni-Holm-Korrekturen wurden verwendet, um die Aussagekraft bei multiplen Tests zu erhöhen. Zunächst wird in der Problemstellung das Datenset sowie die zu analysierenden Fragestellungen detailliert beschrieben. Anschließend werden im Abschnitt zu den statistischen Methoden die verwendeten Verfahren wie Chi-Quadrat-Test und exakter Fisher-Test ausführlich erläutert. Die Ergebnisse der Tests werden in der statistischen Auswertung präsentiert und interpretiert. Abschließend werden in der Zusammenfassung die wichtigsten Erkenntnisse des Berichts hervorgehoben und kritisch reflektiert.

2 Problemstellung

In diesem Abschnitt werden die zentralen Eigenschaften des Datensatzes der Olympischen Spiele 2024 sowie die Ziele des Projekts beschrieben. Das Datenmaterial umfasst die Medaillendaten der fünf erfolgreichsten Nationen und ihre Erfolge. Zudem werden die inhaltlichen und statistischen Zielsetzungen erläutert, die auf die Analyse von Zusammenhängen zwischen Sportarten, Ländern und Medaillenfarben abzielen.

2.1 Datenmaterial

Der Datensatz basiert auf den offiziellen Angaben der Olympischen Spiele 2024, bereitgestellt von der Internationalen Olympischen Kommission. Sie umfassen die aggregierten Medaillendaten der fünf erfolgreichsten Nationen (USA, China, Japan, Australien und Frankreich) in ausgewählten Sportarten. Der Erhebungsprozess durch die IOC basiert auf den offiziellen Wettkampfergebnissen, die nach Abschluss der Olympischen Spiele validiert und veröffentlicht wurden (vgl. International Olympic Committee, 2024, Abschnitt „Medaillen“). Die vorliegenden Daten wurden anschließend in vier Sportartgruppen kategorisiert, nämlich Kampfsport, Leichtathletik, Ballsportarten und Schwimmen. Zusätzliche Berechnungen wie die Gesamtanzahl der Medaillen pro Land wurden auf Basis der bereitgestellten Gold-, Silber- und Bronzemedailles durchgeführt. Die Stichprobe besteht aus 20 Beobachtungen, die die Leistungen der fünf Nationen in den vier Sportartgruppen abbilden. Die Variablen im Datensatz umfassen **Land** und **Sportart**. **Land** bezeichnet den Namen der Nation, während **Sportart** die verschiedenen Sportarten gruppiert; beide sind nominal. **NrGold**, **NrSilber** und **NrBronze** geben die Anzahl der gewonnenen Gold-, Silber- und Bronzemedailles an, und alle drei Variablen sind metrisch-diskret. **Total** beschreibt die Gesamtanzahl der gewonnenen Medaillen und ist ebenfalls metrisch-diskret. Die Datenqualität ist hoch, da die Daten aus einer geprüften, offiziellen Quelle stammen und keine fehlenden Werte enthalten. Die Medaillenergebnisse wurden aus den offiziellen Wettkämpfen mit hoher Messgenauigkeit erfasst und anschließend automatisiert verarbeitet sowie in einer bereitgestellten Datei veröffentlicht.

2.2 Zielsetzung

Das Projekt verfolgt sowohl inhaltliche als auch statistische Ziele. Inhaltlich sollen die Zusammenhänge zwischen den Nationen und ihren Erfolgen in verschiedenen Sportarten untersucht werden. Zudem soll analysiert werden, wie sich die Medaillenfarben innerhalb der Länder und Sportarten verteilen. Die statistischen Ziele umfassen die Überprüfung der Abhängigkeit zwischen Sportart und Land in Bezug auf die Gesamtanzahl der Medaillen mittels eines Chi-Quadrat-Tests, die Analyse der Abhängigkeit zwischen Medaillenfarbe und Land für jede Sportart mithilfe eines exakten Fisher-Tests sowie die Untersuchung der Abhängigkeit zwischen Medaillenfarbe und Sportart innerhalb der Länder unter Anwendung des exakten Fisher-Tests. Diese Untersuchungen sollen helfen, systematische Muster und Zusammenhänge in den Medaillendaten der Olympischen Spiele 2024 aufzudecken.

3 Statistische Methoden

In diesem Kapitel werden die statistischen Methoden beschrieben, die zur Analyse der Medaillendaten der Olympischen Spiele 2024 verwendet wurden. Die Analyse wurde in R (Version 4.2.1 (2022-06-23 ucrt), vgl. R-Core Team, 2022) durchgeführt. Zur Datenmanipulation wurde **dplyr** (Version 1.1.4, vgl. Wickham et al., 2023, S. 45–50) verwendet, **ggplot2** (Version 3.5.1, vgl. Wickham, 2016, *Elegant Graphics for Data Analysis*, S. 120–135) unterstützte die Visualisierung, und **readxl** (Version 1.4.3, vgl. Wickham Bryan, 2019, S. 25–30) wurde für das Einlesen der Excel-Datei genutzt. Ergänzend kam **tidyr** (Version 1.3.1, vgl. Wickham Henry, 2023, S. 60–75) zur Umstrukturierung der Daten zum Einsatz, Während **reshape2** (Version 1.4.4, vgl. Wickham, 2007, S. 15–20) Aufgaben zur Transformation und Umstrukturierung von Daten unterstützte.

3.1 Kontingenztabelle

Eine Kontingenztabelle zeigt die gemeinsame Verteilung zweier Merkmale U und V mit den Ausprägungen $u_1, u_2, \dots, u_r$ für U und $v_1, v_2, \dots, v_s$ für V . Die Werte h_{kl} stellen die Häufigkeiten dar, mit denen die Kombination (u_k, v_l) in den Daten vorkommt, wobei $k = 1, \dots, r$ und $l = 1, \dots, s$. Die Struktur der Tabelle kann wie folgt dargestellt werden: In dieser Darstellung bezeichnet h_{kl} die absolute Häufigkeit der Kombination

Tabelle 1: Kontingenztabelle mit beobachteten Häufigkeiten h_{ij} .

	v_1	v_2	$\dots$	v_s	$h_{k\cdot}$
u_1	h_{11}	h_{12}	$\dots$	h_{1s}	$h_{1\cdot}$
u_2	h_{21}	h_{22}	$\dots$	h_{2s}	$h_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
u_r	h_{r1}	h_{r2}	$\dots$	h_{rs}	$h_{r\cdot}$
$h_{\cdot l}$	$h_{\cdot 1}$	$h_{\cdot 2}$	$\dots$	$h_{\cdot s}$	h

(u_k, v_l) . Die Randhäufigkeiten für die Zeilen und Spalten werden durch $h_{k\cdot} = \sum_{l=1}^s h_{kl}$ und $h_{\cdot l} = \sum_{k=1}^r h_{kl}$ berechnet. Die Gesamtanzahl der Beobachtungen ergibt sich aus $h = \sum_{k=1}^r \sum_{l=1}^s h_{kl}$. Die Kontingenztabelle bietet eine klare Übersicht über die gemeinsame Verteilung der Merkmale sowie deren Randverteilungen, was für die Analyse von Abhängigkeiten zwischen U und V nützlich ist. (vgl. Multivariate Deskription und Exploration, Kapitel 3, S. 116–117)

3.2 Chi-Quadrat-Test

Der Chi-Quadrat-Test wird verwendet, um zu prüfen, ob zwei kategoriale Merkmale, bezeichnet als X und Y , unabhängig voneinander sind. Die Grundlage des Tests bildet eine zweidimensionale Kontingenztafel mit k Kategorien von X und ℓ Kategorien von Y . Die Kontingenztafel zeigt die beobachteten Häufigkeiten h_{ij} , die die Anzahl der Beobachtungen für jede Kombination der Merkmalsausprägungen x_i von X und y_j von Y darstellen, wobei $i = 1, \dots, k$ und $j = 1, \dots, \ell$. Die Hypothesen lauten:

$$H_0: P(X, Y) = P(X) \cdot P(Y) \quad \text{vs.} \quad H_1: P(X, Y) \neq P(X) \cdot P(Y)$$

Dies bedeutet, dass die Merkmale X und Y unabhängig bzw. abhängig voneinander sind. Die Teststatistik für den Chi-Quadrat-Test wird definiert als

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^{\ell} \frac{(h_{ij} - m_{ij})^2}{m_{ij}},$$

wobei h_{ij} die beobachteten Häufigkeiten und m_{ij} die erwarteten Häufigkeiten sind. Die erwarteten Häufigkeiten m_{ij} werden unter der Annahme der Unabhängigkeit der Merkmale berechnet:

$$m_{ij} = \frac{h_{i.} \cdot h_{.j}}{h},$$

wobei $h_{i.} = \sum_{j=1}^{\ell} h_{ij}$ die Randhäufigkeiten der Zeilen, $h_{.j} = \sum_{i=1}^k h_{ij}$ die Randhäufigkeiten der Spalten und $h = \sum_{i=1}^k \sum_{j=1}^{\ell} h_{ij}$ die Gesamtanzahl der Beobachtungen darstellt (vgl. Bortz Schuster, 7. Auflage, S. 138). Unter der Nullhypothese folgt die Teststatistik einer Chi-Quadrat-Verteilung mit $(k - 1) \cdot (\ell - 1)$ Freiheitsgraden. Der kritische Wert wird aus der Chi-Quadrat-Verteilung für ein vorgegebenes Signifikanzniveau α bestimmt. Wenn der berechnete Wert der Teststatistik größer als der kritische Wert ist, wird die Nullhypothese H_0 verworfen. Andernfalls kann H_0 nicht verworfen werden. Für die Anwendung des Chi-Quadrat-Tests gelten folgende Voraussetzungen: Die Daten stammen aus einer einfachen Zufallsstichprobe, die Beobachtungen sind unabhängig voneinander und können eindeutig einer Zelle der Kontingenztafel zugeordnet werden (vgl. Bortz Schuster, 7. Auflage). Die erwarteten Häufigkeiten m_{ij} in jeder Kategorie sollten mindestens 1 betragen. Zudem dürfen höchstens 20% der Kategorien erwartete Häufigkeiten unter 5 aufweisen, um die Gültigkeit der Chi-Quadrat-Approximation zu gewährleisten (vgl. Duller, 2018, S. 110-111). Wird diese Voraussetzung verletzt, sollte auf alternative Tests wie den exakten Fisher-Test zurückgegriffen werden. Die Chi-Quadrat-Teststatistik

gibt an, wie stark die beobachteten Häufigkeiten h_{ij} von den erwarteten Häufigkeiten m_{ij} abweichen. Große Abweichungen führen zu hohen Werten der Teststatistik, was auf eine Verletzung der Unabhängigkeit hinweisen kann. Kleine Abweichungen deuten hingegen darauf hin, dass die Merkmale unabhängig voneinander sein könnten (vgl. Bortz Schuster, 7. Auflage, S.140-141).

3.3 Exakter Test nach Fisher

Der Exakte Test nach Fisher überprüft die Unabhängigkeit zwischen zwei nominalskalierten Variablen in einer Kontingenztafel. Er wird insbesondere bei kleinen Stichproben verwendet, bei denen approximative Verfahren wie der χ^2 -Test ungenau sein können. Der Test basiert auf der exakten Berechnung von Wahrscheinlichkeiten, wodurch keine Annahmen über asymptotische Verteilungen erforderlich sind (vgl. Büning und Trenkler, 1994, S. 229–230). Die Nullhypothese H_0 lautet, dass die beiden Variablen unabhängig sind. Mathematisch bedeutet dies, dass für alle Kombinationen (i, j) die Wahrscheinlichkeit für das gemeinsame Auftreten p_{ij} als Produkt der Randwahrscheinlichkeiten geschrieben werden kann:

$$H_0 : p_{ij} = p_{i\cdot} \cdot p_{\cdot j} \quad \text{vs.} \quad H_1 : p_{ij} \neq p_{i\cdot} \cdot p_{\cdot j} \text{ für mindestens ein Paar } (i, j).$$

Hierbei sind $p_{i\cdot}$ und $p_{\cdot j}$ die Randwahrscheinlichkeiten der Zeilen- bzw. Spaltenkategorien. Für eine gegebene Kontingenztafel K^* mit Randhäufigkeiten R bestimmt der Test die Wahrscheinlichkeit, dass diese oder extremere Tabellen unter der Annahme der Unabhängigkeit auftreten. Die Berechnung erfolgt durch die Fixierung der Randhäufigkeiten, während die Zelleneinträge variiert werden, wobei alle möglichen Kontingenztafeln mit denselben Randhäufigkeiten berücksichtigt werden. Für eine 2×2 -Tabelle ergibt sich die Wahrscheinlichkeit einer bestimmten Tabelle K aus der hypergeometrischen Verteilung:

$$P(K \mid R) = \frac{\binom{a+c}{a} \cdot \binom{b+d}{b}}{\binom{n}{a+b}},$$

wobei a, b, c, d die Zelleneinträge sind und $n = a + b + c + d$ die Gesamtanzahl der Beobachtungen ist (vgl. Büning und Trenkler, 1994, S. 229). Der p-Wert wird berechnet, indem die Wahrscheinlichkeiten aller Tabellen aufsummiert werden, die mindestens so extrem sind wie die beobachtete Tabelle K^* . Dies wird durch die Bedingung $P(K \mid R) \leq P(K^* \mid R)$ festgelegt. Für größere $(k \times m)$ -Kontingenztafeln wird die Berechnung der Wahrscheinlichkeiten zunehmend komplex. Der Exakte Test nach Fisher nutzt hierfür den „Netzwerk-

Algorithmus“, der von Mehta und Patel (1983, S. 427) entwickelt wurde, um die Berechnung effizienter zu gestalten. Dieser Algorithmus erlaubt es, die exakte Wahrscheinlichkeit auch für größere Tabellen mit höherer Dimension präzise zu bestimmen. Bei Tabellen mit $k = 2$ und $m > 2$ wird alternativ die Multinomialverteilung (Freeman-Halton-Test) herangezogen (vgl. Mehta und Patel, 1983, S. 427). Die Voraussetzungen für den Test beinhalten, dass die Daten aus einer einfachen Zufallsstichprobe stammen, die Beobachtungen unabhängig sind und jede Kombination der Variablen eindeutig einer Zelle zugeordnet werden kann. Darüber hinaus müssen die Randhäufigkeiten fixiert sein, um die Berechnung der Wahrscheinlichkeiten zu ermöglichen (vgl. Büning und Trenkler, 1994, S. 230). Der Exakte Test nach Fisher bietet eine präzise Methode zur Untersuchung von Unabhängigkeiten zwischen kategorialen Variablen, insbesondere bei kleinen Stichproben. Er wird häufig bevorzugt, da er exakte Ergebnisse liefert, jedoch bei größeren Tabellen oder Stichproben aufgrund der Berechnungskomplexität ineffizient werden kann. Durch den Einsatz des Netzwerk-Algorithmus oder spezialisierter numerischer Verfahren können diese Herausforderungen jedoch überwunden werden (vgl. Mehta und Patel, 1983, S. 427).

4 Statistische Auswertung

In diesem Kapitel werden die Medaillendaten der Olympischen Spiele 2024 zunächst deskriptiv analysiert, um eine grundlegende Übersicht über die Verteilung der Variablen zu erhalten. Anschließend werden die in Kapitel 3 beschriebenen statistischen Methoden angewendet, um die zentralen Fragestellungen zu beantworten. Zunächst wird die Abhängigkeit zwischen der Sportart und dem Land in Bezug auf die Gesamtanzahl der gewonnenen Medaillen untersucht. Dabei wird der χ^2 -Unabhängigkeitstest verwendet, um mögliche Zusammenhänge zu identifizieren. Für die zweite Fragestellung, die den Zusammenhang zwischen der Medaillenfarbe und dem Land innerhalb jeder Sportart betrachtet, wird der Exakte Test nach Fisher eingesetzt, da die Voraussetzungen des χ^2 -Tests nicht erfüllt sind. Gleiches gilt für die dritte Analyse, bei der die Abhängigkeit zwischen der Medaillenfarbe und der Sportart innerhalb jedes Landes untersucht wird. In allen Analysen wird davon ausgegangen, dass die Daten unabhängig voneinander sind, auch wenn dies nicht empirisch geprüft wurde. Die Ergebnisse dieser Analysen liefern Einblicke in die Verteilung und Abhängigkeiten der Medaillendaten.

4.1 Deskriptive Analyse

In Tabelle 2 wird die Verteilung der Medaillen nach Ländern und Sportarten bei den Olympischen Spielen 2024 dargestellt. Insgesamt wurden 215 Medaillen in den Kategorien Ballsport, Kampfsport, Leichtathletik und Schwimmsport vergeben. Die USA dominieren mit 82 Medaillen, insbesondere in Leichtathletik (34) und Schwimmen (29). Die VR China zeigt ihre Stärke im Ballsport und Schwimmen (jeweils 14 Medaillen) und erreicht insgesamt 45 Medaillen. Frankreich erzielt 32 Medaillen, wobei Kampfsport (15) die erfolgreichste Kategorie ist. Australien glänzt mit 19 Medaillen im Schwimmen, bleibt aber in den anderen Disziplinen zurück. Japan zeigt eine klare Spezialisierung auf Kampfsport mit 19 Medaillen und insgesamt 25 Medaillen. Schwimmen (70 Medaillen) und Kampfsport (58 Medaillen) sind die erfolgreichsten Sportarten, gefolgt von Leichtathletik (47) und Ballsport (40). Die Medaillenverteilung unterstreicht die länderspezifischen Stärken: Die USA dominieren in Leichtathletik und Schwimmen, Japan im Kampfsport, während Australien im Schwimmen hervorsticht. Frankreich und die VR China zeigen hingegen eine ausgewogenere Verteilung mit Schwerpunkten in Ballsport und Kampfsport. Zusätz-

Tabelle 2: Gesamtmedaillenverteilung der Länder nach Sportartkategorien.

Land	Ballsport	Kampfsport	Leichtathletik	Schwimmsport	Gesamt
Australien	3	2	7	19	31
Frankreich	9	15	1	7	32
Japan	4	19	1	1	25
USA	10	9	34	29	82
VR China	14	13	4	14	45
Summe	40	58	47	70	215

lich verdeutlicht Abbildung 1 die Verteilung der Gold-, Silber- und Bronzemedailles nach Ländern und Sportarten. Japan zeigt die stärkste Leistung im Kampfsport, während die USA sowohl in Leichtathletik als auch im Schwimmen dominieren. Australien ist vor allem im Schwimmen erfolgreich, während Frankreich und die VR China ihre Schwerpunkte in Ballsportarten und Kampfsport haben. Die Verteilung der Medaillen spiegelt die Spezialisierungen und Stärken der einzelnen Länder in den jeweiligen Sportarten wider.

4.2 Abhängigkeit zwischen Sportart und Land in Bezug auf die Gesamtmedaillenanzahl

Zur Untersuchung der Abhängigkeit zwischen Sportart und Land wurde der χ^2 -Unabhängigkeitstest angewendet, da die Voraussetzungen für diesen Test erfüllt sind. Insbesondere betragen alle erwarteten Häufigkeiten mindestens 1, und höchstens 20% der Zellen weisen erwartete Häufigkeiten von weniger als 5 auf. Die Analyse basierte auf den Daten in Tabelle 3, welche die absoluten und erwarteten Häufigkeiten darstellt. Der berechnete p-Wert

Tabelle 3: Medaillenverteilung der Länder nach Sportartkategorien mit absoluten Häufigkeiten (nicht in Klammern) und erwarteten Häufigkeiten (in Klammern).

Land	Ballsport	Kampfsport	Leichtathletik	Schwimmen	Gesamt
Australien	3 (5.77)	2 (8.36)	7 (6.78)	19 (10.09)	31
Frankreich	9 (5.95)	15 (8.63)	1 (6.99)	7 (10.42)	32
Japan	4 (4.65)	19 (6.74)	1 (5.47)	1 (8.14)	25
USA	10 (15.26)	9 (22.12)	34 (17.93)	29 (26.70)	82
VR China	14 (8.37)	13 (12.14)	4 (9.84)	14 (14.65)	45
Summe	40	58	47	70	215

beträgt 4.189×10^{-14} , und das Signifikanzniveau wurde auf $\alpha = 0.05$ festgelegt. Da der p-Wert deutlich kleiner als α ist, wird die Nullhypothese, dass keine Abhängigkeit zwischen Sportart und Land besteht, verworfen. Dies deutet darauf hin, dass ein signifikanter Zusammenhang zwischen diesen Variablen besteht.

4.3 Abhängigkeit zwischen Medaillenfarbe und Land innerhalb der Sportarten

In dieser Analyse wird die Abhängigkeit zwischen Medaillenfarbe (Gold, Silber, Bronze) und Land für jede Sportartkategorie untersucht. Die Analyse basiert auf den Tabellen 8 bis 11 (siehe Anhang B, S. 14–15), welche die Medaillenverteilung der einzelnen Länder getrennt nach Sportartkategorien darstellen. Dabei sind die beobachteten Häufigkeiten direkt angegeben, während die erwarteten Häufigkeiten in Klammern ergänzt wurden. Die Nullhypothese H_0^X besagt, dass die Verteilung der Medaillenfarben (Gold, Silber, Bronze) in der Sportart X unabhängig vom Land ist. Die Alternativhypothese H_1^X nimmt an, dass ein Zusammenhang zwischen Medaillenfarbe und Land in der Sportart X besteht. Hierbei steht B für Ballsport, K für Kampfsport, L für Leichtathletik und S für Schwimmen. Aufgrund der Verletzung der Voraussetzungen des χ^2 -Unabhängigkeitstests,

insbesondere da in mehreren Tabellen mehr als 20% der erwarteten Häufigkeiten unter 5 liegen, wurde der Exakte Test nach Fisher verwendet. Die Ergebnisse des Fisher-Tests sind in Tabelle 4 dargestellt. Vor der Adjustierung zeigte sich für die Kategorie Ballsport ein signifikanter Zusammenhang zwischen Medaillenfarbe und Land ($p = 0.02756$), so dass die Nullhypothese H_0^B verworfen wurde. Für die anderen Kategorien Kampfsport ($p = 0.29970$), Leichtathletik ($p = 0.53480$) und Schwimmen ($p = 0.25490$) wurden die Nullhypothesen beibehalten, da die p-Werte in allen Fällen größer als 0.05 sind. Nach

Tabelle 4: Ergebnisse des Fisher-Tests für jede Sportartkategorie.

Sportartkategorie	p-Wert	Testentscheidung
Ballsport	0.02756	H_0^B verwerfen
Kampfsport	0.29970	H_0^K beibehalten
Leichtathletik	0.53480	H_0^L beibehalten
Schwimmen	0.25490	H_0^S beibehalten

der Bonferroni-Holm-Adjustierung der p-Werte (Tabelle 5) wird jedoch auch für die Kategorie Ballsport H_0^B beibehalten, da der adjustierte p-Wert ($p_{\text{adjustiert}} = 0.11024$) die Signifikanzgrenze von 0.05 überschreitet. Somit wird nach der Adjustierung für keine der Sportarten ein signifikanter Zusammenhang zwischen Medaillenfarbe und Land festgestellt. Dies deutet darauf hin, dass die Verteilung der Medaillenfarben in den betrach-

Tabelle 5: Adjustierte p-Werte nach der Bonferroni-Holm Methode.

Sportartkategorie	p-Wert	Testentscheidung
Ballsportart	0.11024	H_0^B beibehalten
Kampfsport	0.76470	H_0^K beibehalten
Leichtathletik	0.76470	H_0^L beibehalten
Schwimmen	0.76470	H_0^S beibehalten

teten Sportartkategorien unabhängig vom Land ist. Die Verwendung des Exakten Tests nach Fisher gewährleistet exakte Ergebnisse, insbesondere bei kleinen Häufigkeiten, wie sie in den Tabellen für Medaillenfarbe und Land vorliegen. Die Adjustierung der p-Werte nach der Bonferroni-Holm-Methode reduziert das Risiko von Fehlinterpretationen aufgrund multipler Tests und unterstreicht die Robustheit der Ergebnisse. Zusammenfassend zeigt die Analyse, dass nach Adjustierung der p-Werte kein signifikanter Zusammenhang zwischen Medaillenfarbe und Land für die betrachteten Sportartkategorien festgestellt werden kann.

4.4 Untersuchung der Abhängigkeit zwischen Medaillenfarbe und Sportart innerhalb der Länder

In dieser Analyse wird die Abhängigkeit zwischen Medaillenfarbe (Gold, Silber, Bronze) und Sportart innerhalb der Länder untersucht. Die Tabellen 12 bis 16 (siehe Anhang C, S. 15–16) bieten eine detaillierte Übersicht der Medaillenverteilung, jeweils separat für die fünf analysierten Länder. Jede Tabelle zeigt, wie die Medaillenfarben auf die verschiedenen Sportartkategorien verteilt sind. Die tatsächlich beobachteten Häufigkeiten werden direkt angegeben, während die erwarteten Häufigkeiten in Klammern dargestellt sind. Die Nullhypothese H_0^K besagt, dass innerhalb des Landes K die Verteilung der Medaillenfarben unabhängig von der Sportart ist. Die Alternativhypothese H_1^K nimmt an, dass innerhalb des Landes K ein Zusammenhang zwischen Medaillenfarbe und Sportart besteht. Aufgrund der Verletzung der Voraussetzungen des χ^2 -Unabhängigkeitstests, insbesondere da in mehreren Tabellen mehr als 20% der erwarteten Häufigkeiten unter 5 liegen, wurde der Exakte Test nach Fisher verwendet. Die Ergebnisse des Fisher-Tests vor der Adjustierung der p-Werte sind in Tabelle 6 dargestellt. Die Ergebnisse zeigen, dass für Japan (JPN, $p = 0.04942$) und die VR China (VRC, $p = 0.03666$) ein signifikanter Zusammenhang zwischen Medaillenfarbe und Sportart besteht. Für diese Länder wurden die Nullhypothesen H_0^{JPN} und H_0^{VRC} verworfen, da die p-Werte kleiner als 0.05 sind. Für Australien (AUS, $p = 0.18370$), Frankreich (FRA, $p = 0.23340$) und die USA (USA, $p = 0.34310$) wurde die Nullhypothese hingegen beibehalten, da die p-Werte in allen Fällen größer als 0.05 sind. Diese Ergebnisse deuten darauf hin, dass für Japan und die VR China vor der Adjustierung möglicherweise Abhängigkeiten zwischen Medaillenfarbe und Sportart bestehen, während für die anderen Länder keine solche Abhängigkeit festgestellt wird. Nach

Tabelle 6: Ergebnisse der Fisher-Tests für jedes Land.

Land	p-Wert	Testentscheidung
Australien (AUS)	0.18370	H_0^{AUS} beibehalten
Frankreich (FRA)	0.23340	H_0^{FRA} beibehalten
Japan (JPN)	0.04942	H_0^{JPN} verwerfen
USA (USA)	0.34310	H_0^{USA} beibehalten
VR China (VRC)	0.03666	H_0^{VRC} verwerfen

der Adjustierung der p-Werte mittels der Bonferroni-Holm-Methode (Tabelle 7) konnte jedoch für keines der Länder ein signifikanter Zusammenhang festgestellt werden. Für Japan (JPN, $p_{\text{adjustiert}} = 0.19768$) und die VR China (VRC, $p_{\text{adjustiert}} = 0.18330$) überschreiten die adjustierten p-Werte die Signifikanzgrenze von 0.05, sodass die Nullhypothesen

H_0^{JPN} und H_0^{VRC} beibehalten werden. Auch für Australien (AUS, $p_{\text{adjustiert}} = 0.55110$), Frankreich (FRA, $p_{\text{adjustiert}} = 0.55110$) und die USA (USA, $p_{\text{adjustiert}} = 0.55110$) bleibt die Beibehaltung der Nullhypothese unverändert. Dies zeigt, dass die zuvor beobachteten Unterschiede für Japan und die VR China nach der Adjustierung nicht mehr signifikant sind.

Tabelle 7: Adjustierte p-Werte nach der Bonferroni-Holm Methode.

Land	p-Wert	Testentscheidung
Australien (AUS)	0.55110	H_0^{AUS} beibehalten
Frankreich (FRA)	0.55110	H_0^{FRA} beibehalten
Japan (JPN)	0.19768	H_0^{JPN} beibehalten
USA (USA)	0.55110	H_0^{USA} beibehalten
VR China (VRC)	0.18330	H_0^{VRC} beibehalten

Die Adjustierung der p-Werte nach der Bonferroni-Holm-Methode reduziert das Risiko von Fehlinterpretationen aufgrund multipler Tests.

Zusammenfassend zeigt die Analyse, dass nach der Adjustierung kein signifikanter Zusammenhang zwischen Medaillenfarbe und Sportart innerhalb der Länder festgestellt werden kann. Die vorherigen Ergebnisse für Japan und die VR China lassen sich durch zufällige Schwankungen erklären, was die Robustheit der adjustierten Testergebnisse unterstreicht.

5 Zusammenfassung

Dieses Projekt untersuchte die Medaillendaten der Olympischen Spiele 2024, die vom 26. Juli bis 11. August 2024 stattfanden. Insgesamt nahmen 11.119 Athletinnen und Athleten aus 206 Ländern an den Spielen teil, und es wurden Medaillen in 329 Wettkämpfen über 32 Sportarten hinweg vergeben. Die zugrunde liegenden Daten umfassten die aggregierten Medaillenergebnisse der fünf erfolgreichsten Nationen (USA, VR China, Japan, Australien und Frankreich) in den Kategorien Ballsport, Kampfsport, Leichtathletik und Schwimmen. Es wurde davon ausgegangen, dass die Daten unabhängig voneinander sind, auch wenn diese Annahme nicht empirisch geprüft wurde. Die Analyse basierte auf einem Signifikanzniveau von $\alpha = 0.05$. Ziel der Analyse war es, die Verteilung der Medaillen zu untersuchen und systematische Muster aufzudecken. Drei zentrale Fragestellungen wurden adressiert: Erstens die Abhängigkeit zwischen Sportart und Land, zweitens die Abhängigkeit zwischen Medaillenfarbe und Land innerhalb jeder Sportart und drittens die Abhängigkeit zwischen Medaillenfarbe und Sportart innerhalb der Länder. Die statistische Auswertung umfasste deskriptive Analysen, χ^2 -Tests sowie Exakte Tests nach Fisher, um die Fragestellungen zu beantworten. Die Ergebnisse zeigten, dass ein signifikanter Zusammenhang zwischen Sportart und Land in Bezug auf die Gesamtmedaillenanzahl besteht. Die Analyse der Abhängigkeit zwischen Medaillenfarbe und Land innerhalb der Sportarten ergab signifikante Zusammenhänge in der Kategorie Ballsport vor der Adjustierung. Nach der Adjustierung der p-Werte mittels der Bonferroni-Holm-Methode wurden jedoch keine signifikanten Zusammenhänge mehr festgestellt. Ähnliches zeigte sich bei der Untersuchung der Abhängigkeit zwischen Medaillenfarbe und Sportart innerhalb der Länder: Während vor der Adjustierung für Japan und die VR China Abhängigkeiten beobachtet wurden, führten die adjustierten Ergebnisse zur Beibehaltung der Nullhypothesen für alle Länder. Die Analyse verdeutlichte die länderspezifischen Stärken: Die USA dominierten in Leichtathletik und Schwimmen, Japan zeigte eine Spezialisierung im Kampfsport, und die VR China war besonders erfolgreich im Ballsport. Dennoch legen die Ergebnisse nahe, dass die Verteilung der Medaillenfarben in den meisten Fällen unabhängig von

Land oder Sportart ist. Die angewendeten Verfahren gewährleisteten robuste Ergebnisse, wobei die Adjustierung der p-Werte dazu beitrug, das Risiko von Fehlinterpretationen aufgrund multipler Tests zu minimieren. Zukünftige Untersuchungen könnten eine größere Stichprobe einbeziehen, die mehr Länder und Sportarten umfasst, um eine breitere Analyse der Medaillenverteilung zu ermöglichen. Zusätzlich könnten auch Daten aus anderen Olympischen Spielen in verschiedenen Jahren und Bereichen herangezogen werden, um langfristige Trends zu identifizieren und zu überprüfen, ob der Erfolg in einem bestimmten Sport tatsächlich mit einem spezifischen Land verbunden ist oder ob er durch andere Faktoren beeinflusst wird. Dies würde helfen, systematische Muster besser zu verstehen und mögliche Ausnahmen oder Veränderungen im Laufe der Zeit zu erkennen.

Literatur

- Bortz, J., Schuster, C. *Statistik für Sozialwissenschaftler*. 7. Auflage, Springer, 2010. S. 138, 140–141.
- Büning, H., Trenkler, G. *Nichtparametrische statistische Methoden*. Springer-Verlag, 1994. S. 229–230.
- Duller, C. *Einführung in die Statistik mit R*. Springer, 2018. S. 110–111.
- International Olympic Committee. *Medaillen der Olympischen Spiele Paris 2024*. Zuletzt aktualisiert am 11. August 2024 um 22:56 Uhr. Verfügbar unter: <https://olympics.com/de/paris-2024/medaillen>. Abgerufen am 5. Januar 2025.
- Mehta, C. R., Patel, N. R. *A Network Algorithm for Performing Fisher's Exact Test in $r \times c$ Contingency Tables*. Journal of the American Statistical Association, 1983. S. 427.
- Multivariate Deskription und Exploration. Kapitel 3, S. 116–117.
- R Core Team. *R: A Language and Environment for Statistical Computing*. Version 4.2.1, 2022. Verfügbar unter: <https://www.r-project.org>.
- Statista. *Anzahl der teilnehmenden Nationen bei Olympischen Sommerspielen weltweit von 1896 bis 2024*. Veröffentlicht von B. Zeppenfeld, 12.08.2024. Verfügbar unter: <https://de.statista.com/statistik/daten/studie/236506/umfrage/anzahl-der-teilnehmenden-nationen-bei-olympischen-sommerspielen/>. Abgerufen am 3. Januar 2025.
- Wickham, H. *Elegant Graphics for Data Analysis*. Springer-Verlag New York, 2016. S. 120–135.
- Wickham, H. *reshape2: Flexibly Reshape Data: A Reboot of the Reshape Package*. Version 1.4.4, 2007. S. 15–20.
- Wickham, H., Bryan, J. *readxl: Import Excel Files into R*. Version 1.4.3, 2019. S. 25–30.
- Wickham, H., François, R., Henry, L., Müller, K., Vaughan, D. *dplyr: A Grammar of Data Manipulation*. Version 1.1.4, 2023. S. 45–50.
- Wickham, H., Henry, L. *tidyr: Tidy Messy Data*. Version 1.3.1, 2023. S. 60–75.

Anhang

A: Medaillenverteilung nach Ländern und Sportarten




Abbildung 1: Häufigkeiten der Gold-, Silber- und Bronzemedailles nach Land und Sportart

B: Medaillenverteilung für jede Sportartkategorie

Tabelle 8: Medaillenverteilung für Ballsportart.

Land	Gold	Silber	Bronze	Σ
Australien	1 (1.05)	1 (1.13)	1 (0.83)	3
Frankreich	2 (3.15)	5 (3.38)	2 (2.48)	9
Japan	0 (1.40)	1 (1.50)	3 (1.10)	4
USA	3 (3.50)	2 (3.75)	5 (2.75)	10
VR China	8 (4.90)	6 (3.85)	0 (5.25)	14
Σ	14	15	11	40

C: Medaillenverteilung für jedes Land

Tabelle 9: Medaillenverteilung für Kampfsport.

Land	Gold	Silber	Bronze	Σ
Australien	0 (0.66)	0 (0.45)	2 (0.90)	2
Frankreich	3 (4.91)	4 (3.36)	8 (6.72)	15
Japan	11 (6.22)	3 (4.26)	5 (8.52)	19
USA	2 (2.95)	2 (2.02)	5 (4.03)	9
VR China	3 (4.26)	4 (2.91)	6 (5.83)	13
Σ	19	13	26	58

Tabelle 10: Medaillenverteilung für Leichtathletik.

Land	Gold	Silber	Bronze	Σ
Australien	1 (2.53)	2 (2.23)	4 (2.23)	7
Frankreich	0 (0.36)	1 (0.32)	0 (0.32)	1
Japan	1 (0.36)	0 (0.32)	0 (0.32)	1
USA	14 (12.30)	11 (10.85)	9 (10.85)	34
VR China	1 (1.45)	1 (1.28)	2 (1.28)	4
Σ	17	15	15	47

Tabelle 11: Medaillenverteilung für Schwimmen.

Land	Gold	Silber	Bronze	Σ
Australien	7 (6.24)	9 (7.60)	3 (5.16)	19
Frankreich	4 (2.30)	1 (2.80)	2 (1.90)	7
Japan	0 (0.33)	1 (0.40)	0 (0.27)	1
USA	8 (9.53)	14 (11.60)	7 (7.87)	29
VR China	4 (4.60)	3 (5.60)	7 (3.80)	14
Σ	23	28	19	70

C: Medaillenverteilung für jedes Land

Tabelle 12: Medaillenverteilung für Australien.

Sportartkategorie	Gold	Silber	Bronze	Σ
Ballsportart	1 (0.87)	1 (1.16)	1 (0.97)	3
Kampfsport	0 (0.58)	0 (0.78)	2 (0.65)	2
Leichtathletik	1 (2.03)	2 (2.71)	4 (2.26)	7
Schwimmen	7 (5.52)	9 (7.35)	3 (6.13)	19
Σ	9	12	10	31

Tabelle 13: Medaillenverteilung für Frankreich.

Sportartkategorie	Gold	Silber	Bronze	Σ
Ballsportart	2 (2.53)	5 (3.09)	2 (3.38)	9
Kampfsport	3 (4.22)	4 (5.16)	8 (5.62)	15
Leichtathletik	0 (0.28)	1 (0.34)	0 (0.38)	1
Schwimmen	4 (1.97)	1 (2.41)	2 (2.62)	7
Σ	9	11	12	32

Tabelle 14: Medaillenverteilung für Japan.

Sportartkategorie	Gold	Silber	Bronze	Σ
Ballsportart	0 (1.92)	1 (0.80)	3 (1.28)	4
Kampfsport	11 (9.12)	3 (3.80)	5 (6.08)	19
Leichtathletik	1 (0.48)	0 (0.20)	0 (0.32)	1
Schwimmen	4 (0.48)	1 (0.20)	2 (0.32)	7
Σ	16	5	10	31

Tabelle 15: Medaillenverteilung für USA.

Sportartkategorie	Gold	Silber	Bronze	Σ
Ballsportart	3 (3.29)	2 (3.54)	5 (3.17)	10
Kampfsport	2 (2.96)	2 (3.18)	5 (2.85)	9
Leichtathletik	14 (11.20)	11 (12.00)	9 (10.80)	34
Schwimmen	8 (9.55)	14 (10.30)	7 (9.20)	29
Σ	27	29	26	82

Tabelle 16: Medaillenverteilung für VR China.

Sportartkategorie	Gold	Silber	Bronze	Σ
Ballsportart	8 (4.98)	6 (4.36)	0 (4.67)	14
Kampfsport	3 (4.62)	4 (4.04)	6 (4.33)	13
Leichtathletik	1 (1.42)	1 (1.24)	2 (1.33)	4
Schwimmen	4 (4.98)	3 (4.36)	7 (4.67)	14
Σ	16	14	15	45