

„ TU DORTMUND

FALLSTUDIEN I

Projekt 5: Logistische Regression

Dozenten:

Prof. Dr. Jörg Rahnenführer

M.Sc. Marieke Stolte

Dr. Franziska Kappenberg

Dr. Julia Duda

Autor*in: Ahmed Ghroubi

Gruppennummer: 7

Gruppenmitglieder: Akin Münüsoglu, Salim Abdelkader
Boukrinia, Charbel Sakr

30. Januar 2025

Inhaltsverzeichnis

Inhaltsverzeichnis

1	Einleitung	1
2	Problemstellung	1
2.1	Datenmaterial	2
2.2	Zielsetzung	3
3	Statistische Methoden	3
3.1	Logistische Regression	3
3.2	Best Subset Selection und Akaike-Informationskriterien	4
3.3	Wald-Test und Wald-Konfidenzintervall	5
3.4	Kreuzvalidierung	6
3.5	Analyse der Klassifikationsgüte mit der Receiver Operating Characteristic (ROC) und der Area Under the Curve (AUC)	7
4	Statistische Auswertung	8
4.1	Deskriptive Analyse	9
4.2	Modellierung der Wahlergebnisse mit logistischer Regression	10
4.3	Reduziertes Modell: Variablenselektion und Interpretation	11
4.4	Vergleich der Modellgüte mittels ROC-Kurven und AUC	11
5	Zusammenfassung	12
	Literatur	13
A	Zusätzliche Grafiken	16

1 Einleitung

Das Electoral College ist ein zentraler Bestandteil des Wahlsystems der Vereinigten Staaten und bestimmt den Präsidenten durch eine indirekte Abstimmung. Am 5. November 2024 erfolgt die Wahl der Delegierten, wobei jeder Bundesstaat eine Anzahl von Wahlmännern entsprechend seiner Bevölkerungsgröße erhält. Der Wahlausgang hängt nicht nur von der Gesamtzahl der Stimmen ab, sondern auch von deren geografischer Verteilung. Am 17. Dezember 2024 wählt das Electoral College Donald Trump zum Präsidenten. Politische, sozioökonomische und demografische Faktoren wie Bevölkerungsdichte, Arbeitslosenrate, Medianalter und Zugang zur Gesundheitsversorgung beeinflussen das Wahlverhalten. Ziel dieses Projekts ist es, mithilfe statistischer Methoden, insbesondere der logistischen Regression, die Wahlergebnisse zu analysieren und die wichtigsten Einflussfaktoren zu identifizieren. Die Daten werden bereinigt, transformiert und standardisiert, um eine konsistente Basis für die Modellierung zu schaffen. Ein vollständiges Modell mit allen Variablen analysiert mögliche Einflüsse. Mithilfe eines Best-Subset-Selection-Ansatzes entsteht ein reduziertes Modell, das die wichtigsten Prädiktoren hervorhebt. Beide Modelle werden durch Kreuzvalidierung sowie mit ROC-Kurven und AUC-Werten bewertet, um ihre Vorhersagegenauigkeit zu vergleichen. Kapitel 2 beschreibt den Datensatz sowie die Vorbereitung der Variablen für die Modellierung, einschließlich Transformationen und Standardisierungen. Kapitel 3 erläutert die angewendeten statistischen Methoden zur Analyse der Wahlergebnisse, insbesondere die logistische Regression zur Vorhersage und die Variablenselektion zur Identifikation relevanter Einflussfaktoren. Kapitel 4 präsentiert die Ergebnisse der Modellierung, interpretiert die wichtigsten Prädiktoren und vergleicht die Vorhersagekraft des vollständigen und des reduzierten Modells anhand von ROC-Kurven und AUC-Werten. Kapitel 5 fasst die zentralen Erkenntnisse zusammen, reflektiert die Grenzen der Analyse und schlägt Ansätze für zukünftige Untersuchungen vor.

2 Problemstellung

In diesem Abschnitt werden die zentralen Merkmale des Datensatzes zur US-Präsidentenwahl 2024 und die Problemstellung des Projekts dargestellt. Der Datensatz enthält demografische und sozioökonomische Variablen der Bundesstaaten sowie die Wahlergebnisse im Electoral College. Zudem werden die methodischen und inhaltlichen Zielsetzungen zur Analyse der Zusammenhänge zwischen Variablen und Wahlergebnissen erläutert.

2.1 Datenmaterial

Die Daten für dieses Projekt wurden von den Lehrenden bereitgestellt und stammen aus verschiedenen verlässlichen Quellen, darunter offizielle Statistiken, Umfragen und Behördenangaben. Aufgrund der unterschiedlichen Herkunft kann die Datenqualität variieren. Dennoch wurden die Daten umfassend geprüft und bereinigt, um eine hohe Qualität sicherzustellen. Die Variablen des Datensatzes, die in Tabelle 1 zusammengefasst sind, wurden zu unterschiedlichen Zeitpunkten veröffentlicht. Die Gesamtfläche basiert auf Erhebungen des U.S. Census Bureau aus dem Jahr 2010, während Bevölkerungszahl und -dichte auf Daten aus dem Jahr 2020 zurückgreifen. Aktuellere Variablen wie das mediane Alter, die Geburtenrate, die Arbeitslosenrate, der Anteil der Bevölkerung mit Krankenversicherung und die mediane Miete wurden 2023 veröffentlicht. Der Human Development Index stammt aus 2022, während die Zielvariable, die den Gewinner der Wahl abbildet, auf Angaben der Associated Press aus 2024 basiert. Die Genauigkeit der Daten wurde berücksichtigt. Die meisten Variablen sind auf mindestens eine Dezimalstelle genau angegeben, der Human Development Index auf drei Nachkommastellen. Diese hohe Präzision sowie die Konsistenz der Daten gewährleisten eine ausgezeichnete Qualität.

Tabelle 1: Beschreibung der Variablen im Datensatz.

Variable	Beschreibung	Skalenniveau
State	Name des Bundesstaates	Nominalskala
Leading-Candidate	Gewinner bei der Wahl des Electoral College am 5. November 2024 (Harris oder Trump)	Nominalskala
Total-Area	Gesamtfläche des Bundesstaates (in Square Miles)	Verhältnisskala
Population	Geschätzte Bevölkerungszahl	Verhältnisskala
Population-Density	Bevölkerungsdichte im Jahr 2020 (in Einwohner pro Square Mile)	Verhältnisskala
Median-Age	Medianes Alter im Jahr 2023 (in Jahren)	Verhältnisskala
Birth-Rate	Anzahl Frauen im Alter zwischen 15 und 50 Jahren mit Geburten in den vergangenen 12 Monaten im Jahr 2023	Verhältnisskala
HDI	Human Development Index im Jahr 2022	Verhältnisskala
Unemployment-Rate	Arbeitslosenrate	Verhältnisskala
Health-Insurance-Coverage	Prozentualer Anteil der Bevölkerung mit Krankenversicherung	Verhältnisskala
Median-Rent	Mediane Miete (in US-Dollar)	Verhältnisskala

2.2 Zielsetzung

Das Projekt verfolgt sowohl inhaltliche als auch statistische Ziele. Inhaltlich wird untersucht, in welchem Zusammenhang die gegebenen demografischen und sozioökonomischen Variablen zur Modellierung des Wahlergebnisses verwendet werden können. Zudem erfolgt eine Analyse der Faktoren mit dem größten Einfluss auf das Wahlergebnis sowie deren Interpretation in einem reduzierten Modell. Ein weiterer Schwerpunkt liegt auf dem Vergleich der Vorhersagegenauigkeit zwischen dem vollständigen und dem reduzierten Modell. Die statistischen Ziele umfassen die Anwendung der logistischen Regression zur Modellierung des Wahlergebnisses, die Identifikation der wichtigsten Einflussfaktoren mithilfe einer Variablenselektion und die Interpretation der Ergebnisse anhand von Konfidenzintervallen. Abschließend wird die Vorhersagegenauigkeit der Modelle anhand von ROC-Kurven und AUC-Werten bewertet, wobei eine Kreuzvalidierung durchgeführt wird. Diese Untersuchungen dienen dazu, systematische Zusammenhänge in den Wahlergebnissen der Präsidentschaftswahl 2024 aufzudecken.

3 Statistische Methoden

Die statistische Analyse basiert auf R (Version 4.4.2, vgl. R Core Team, 2024) und nutzt spezialisierte R-Pakete für Modellierung, Visualisierung und Evaluation. Die Datenverarbeitung erfolgt mit tidyverse (vgl. Wickham et al., 2019), während ggplot2 (vgl. Wickham, 2016) und patchwork (vgl. Pedersen, 2024) zur grafischen Darstellung dienen. Für die Modellbildung und Variablenselektion werden caret (vgl. Kuhn, 2008), pROC (vgl. Robin et al., 2011), leaps (vgl. Miller, 2024) und bestglm (vgl. McLeod et al., 2020) verwendet. Das Paket glmulti (vgl. Calcagno, 2020) unterstützt die Modelloptimierung. Diese Methodenkombination ermöglicht eine effiziente und fundierte Analyse der Daten von der Vorbereitung bis zur Validierung der Ergebnisse.

3.1 Logistische Regression

Die logistische Regression ist ein statistisches Modell, das Wahrscheinlichkeiten für eine binäre Zielvariable y ($y \in \{0, 1\}$) in Abhängigkeit von erklärenden Kovariablen $\mathbf{x} = (x_1, x_2, \dots, x_k)^\top$ modelliert. Die Zielvariable y liegt auf einer Nominalskala vor, da sie nur zwei mögliche Ausprägungen annimmt, beispielsweise Erfolg/Misserfolg oder Ja/Nein. Ziel ist es, die Wahrscheinlichkeit $\pi_i = P(y_i = 1 \mid \mathbf{x}_i)$ zu schätzen. Die erklärenden Kovariablen $x_1, x_2, \dots, x_k$ können verschiedene Skalenniveaus haben. Sie können kategorial

auf einer Nominal- oder Ordinalskala oder metrisch auf einer Intervall- oder Verhältnisskala definiert sein. Die logistische Funktion verknüpft die Wahrscheinlichkeit π_i mit dem linearen Prädiktor η_i :

$$\pi_i = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)}, \quad \eta_i = \beta_0 + \sum_{j=1}^k \beta_j x_{ij}.$$

Hierbei stellt η_i eine Linearkombination der Kovariablen dar, wobei β_0 den Achsenabschnitt und $\beta_1, \dots, \beta_k$ die Regressionskoeffizienten repräsentieren. Um sicherzustellen, dass die Wahrscheinlichkeiten π_i im Bereich $[0, 1]$ bleiben, wird die logit-Transformation verwendet:

$$g(\pi_i) = \log\left(\frac{\pi_i}{1 - \pi_i}\right) = \eta_i.$$

Die Regressionskoeffizienten β_j quantifizieren den Effekt der Kovariablen x_j auf die log-Odds $g(\pi_i)$. Eine Erhöhung von x_j um eine Einheit bewirkt eine Multiplikation der Odds um $\exp(\beta_j)$. Werte von $\beta_j > 0$ erhöhen die Wahrscheinlichkeit von $y = 1$, während $\beta_j < 0$ sie verringern. Die Modellparameter werden mittels Maximum-Likelihood-Schätzung bestimmt. Die Log-Likelihood-Funktion, die maximiert wird, lautet:

$$\ell(\beta) = \sum_{i=1}^n [y_i \log(\pi_i) + (1 - y_i) \log(1 - \pi_i)].$$

Hierbei wird die iterative Optimierung durch Verfahren wie den iterativ gewichteten Kleinsten-Quadrate-Algorithmus durchgeführt, um die besten Schätzwerte für β_j zu finden. Die logistische Regression ist flexibel, da sie keine Annahmen über die Verteilung der Kovariablen macht. Sie wird häufig eingesetzt, um die Wahrscheinlichkeit für das Auftreten eines bestimmten binären Ereignisses zu modellieren (vgl. Fahrmeir et al., 2009, S. 189–194; Behnke, 2015, S. 43 ff.).

3.2 Best Subset Selection und Akaike-Informationskriterien

Best Subset Selection ist eine Methode zur Variablenselektion, die darauf abzielt, das beste Modell durch Evaluation verschiedener Variablenkombinationen zu identifizieren. Diese Methode wird häufig in der logistischen Regression eingesetzt und ermöglicht die Auswahl eines Modells mit optimaler Vorhersageleistung, indem sie die Modellgüte maximiert und unnötige Variablen eliminiert. Dabei werden Modelle mit unterschiedlichen Anzahlen an erklärenden Variablen $x_1, x_2, \dots, x_p$ erstellt, von einem Modell mit nur einer Variablen bis hin zum Modell, das alle p Variablen enthält. Die Bewertung der Modelle erfolgt anhand

von Gütemaßen wie dem Akaike-Informationskriterium (AIC).

Das AIC wird definiert als

$$AIC_q = -2 \cdot L_q + 2 \cdot (q + 1),$$

wobei L_q die Log-Likelihood des Modells mit q Variablen darstellt und $q + 1$ die Anzahl der geschätzten Parameter ist. Ein kleinerer AIC-Wert weist auf ein besseres Modell hin, da das AIC eine Balance zwischen Modellgüte und Modellkomplexität herstellt. Weitere Bewertungsmetriken umfassen den Anteil der erklärten Varianz (R^2), das für die Anzahl der Variablen korrigierte R^2 (Adjusted R^2) sowie Mallows' C_p , ein Maß für den Vorhersagefehler, das hilft, überflüssige Variablen zu identifizieren. Die Modellparameter werden mittels Maximum-Likelihood-Schätzung berechnet. Dabei wird die Wahrscheinlichkeitsverteilung der Zielvariable $\hat{\pi}_i = P(y_i = 1 \mid \mathbf{x}_i)$ berücksichtigt, wobei y eine binäre Zielvariable auf einer Nominalskala ist. Zur Berechnung der Modellgüte wird eine diagonale Gewichtungsmatrix $\mathbf{V}$ verwendet, die wie folgt definiert ist:

$$\mathbf{V} = \text{diag}(\hat{\pi}_1(1 - \hat{\pi}_1), \hat{\pi}_2(1 - \hat{\pi}_2), \dots, \hat{\pi}_n(1 - \hat{\pi}_n)).$$

Die Ergebnisse der Best Subset Selection liefern eine Rangfolge der Modelle basierend auf den Bewertungsmetriken. Das Modell mit dem kleinsten AIC-Wert oder C_p -Wert wird typischerweise als das beste Modell ausgewählt. Es ist jedoch wichtig, dass eine inhaltliche Bewertung der Modelle erfolgt, um sicherzustellen, dass sie interpretierbar sind und relevante Variablen enthalten. Best Subset Selection ist ein wertvolles Werkzeug zur Identifikation optimaler Variablenkombinationen, erfordert jedoch zusätzliche Validierungsschritte, da sie keine Wechselwirkungen zwischen Variablen berücksichtigt. Durch die Kombination mit Metriken wie AIC und C_p können fundierte Entscheidungen bei der Modellselektion getroffen werden.

3.3 Wald-Test und Wald-Konfidenzintervall

Der Wald-Test dient zur Überprüfung der Signifikanz einzelner Koeffizienten β_j im logistischen Regressionsmodell. Dabei wird getestet, ob eine erklärende Variable x_{ij} einen Einfluss auf die Zielvariable y_i hat. Die Hypothesen lauten:

$$H_0 : \beta_j = 0 \quad \text{gegen} \quad H_1 : \beta_j \neq 0.$$

Die Teststatistik berechnet sich als

$$Z = \frac{\hat{\beta}_j}{\hat{\sigma}(\hat{\beta}_j)}$$

wobei $\hat{\beta}_j$ den geschätzten Regressionskoeffizienten und $\hat{\sigma}(\hat{\beta}_j)$ dessen Standardfehler bezeichnet. Unter der Annahme, dass die Nullhypothese wahr ist, folgt Z approximativ einer Standardnormalverteilung:

$$Z \sim N(0, 1).$$

Auf Basis dieser Verteilung wird der p-Wert berechnet:

$$p = 2 \cdot P(Z \geq |z| \mid H_0),$$

wobei $|z|$ der absolute Wert der beobachteten Teststatistik ist. Ein kleiner p-Wert deutet darauf hin, dass H_0 verworfen werden kann und die Variable als signifikant angesehen wird. Zusätzlich kann ein Konfidenzintervall für β_j konstruiert werden, um eine Schätzung für den wahren Parameterwert zu erhalten. Dieses Intervall ist definiert als

$$[\hat{\beta}_j - u_{(1-\frac{\alpha}{2})} \cdot \hat{\sigma}(\hat{\beta}_j), \hat{\beta}_j + u_{(1-\frac{\alpha}{2})} \cdot \hat{\sigma}(\hat{\beta}_j)],$$

wobei $u_{(1-\frac{\alpha}{2})}$ das entsprechende Quantil der Standardnormalverteilung für das Signifikanzniveau α ist. Wenn das Intervall die Null enthält, kann keine eindeutige Aussage über den Einfluss der Variable getroffen werden. Je breiter das Intervall, desto größer ist die Unsicherheit in der Schätzung. Der Wald-Test wird in der logistischen Regression häufig zur Bewertung der Bedeutung einzelner Prädiktoren verwendet. Allerdings kann er in bestimmten Situationen, wie bei kleinen Stichproben oder stark korrelierten Variablen, problematisch sein. In solchen Fällen kann es sinnvoll sein, alternative Verfahren in Betracht zu ziehen (vgl. Agresti 2007, S.11 und S.106).

3.4 Kreuzvalidierung

Die Kreuzvalidierung ist eine Methode zur Schätzung der Prognosegüte eines Modells. Sie dient dazu, die Modellparameter auf Basis eines Teils der Daten zu schätzen und die Vorhersagegüte mit den übrigen Daten zu überprüfen. Der allgemeine Ablauf der Kreuzvalidierung umfasst folgende Schritte: Zunächst wird der Datensatz in K Teilmengen $D_1, D_2, \dots, D_K$ ungefähr gleicher Größe aufgeteilt. In jedem Iterationsschritt wird eine Teilmenge D_k als Validierungsdatensatz verwendet, während die übrigen $K-1$ Teilmengen

als Trainingsdatensatz zur Schätzung der Modellparameter dienen. Das Modell wird mit den geschätzten Parametern auf die Daten im Validierungsdatensatz angewendet, und die quadratischen Prognosefehler werden berechnet und aufsummiert. Dieser Prozess wird für jede der K Teilmengen wiederholt, sodass jede Teilmenge einmal als Validierungsdatensatz dient. Der Gesamtfehler wird anschließend durch die Summe der quadratischen Prognosefehler über alle Iterationen berechnet. Das Modell mit dem geringsten Gesamtfehler wird als das beste Modell ausgewählt. Nach Abschluss der Kreuzvalidierung werden die endgültigen Modellparameter auf Basis aller Daten geschätzt (vgl. Fahrmeir et al. 2009, S.161-162).

3.5 Analyse der Klassifikationsgüte mit der Receiver Operating Characteristic (ROC) und der Area Under the Curve (AUC)

Ein wesentliches Instrument zur Bewertung binärer Klassifikationsmodelle ist die Receiver Operating Characteristic (ROC)-Kurve. Sie veranschaulicht, wie gut ein Modell zwischen zwei Klassen unterscheidet, indem die Sensitivität (True Positive Rate, TPR) gegenüber der Spezifität ($1 - \text{False Positive Rate}$, FPR) für verschiedene Schwellenwerte aufgetragen wird. Die Fläche unter dieser Kurve, bekannt als Area Under the Curve (AUC), dient als zusammenfassendes Maß für die Klassifikationsgüte. Die Berechnung der ROC-Kurve basiert auf der Konfusionsmatrix, die die tatsächlichen und vorhergesagten Klassifikationen des Modells zusammenfasst. Sie enthält vier Einträge: wahre positive (TP) und wahre negative (TN) Klassifikationen, die korrekte Vorhersagen darstellen, sowie falsche positive (FP) und falsche negative (FN) Klassifikationen, die Fehlklassifikationen widerspiegeln. Tabelle 2 zeigt diese Matrix. Auf Basis dieser Einträge werden die beiden zentralen Kenn-

Tabelle 2: Konfusionsmatrix für binäre Klassifikationen.

		Vorhergesagt	
		Positiv	Negativ
2*Beobachtet	Positiv	TP (True Positive)	FN (False Negative)
	Negativ	FP (False Positive)	TN (True Negative)

zahlen für die ROC-Kurve berechnet:

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}.$$

Die ROC-Kurve entsteht, indem für verschiedene Schwellenwerte die entsprechenden Werte von TPR und FPR ermittelt und in einem Diagramm aufgetragen werden. Ein Modell,

das gut zwischen den Klassen unterscheidet, weist eine Kurve auf, die sich stark der oberen linken Ecke des Diagramms annähert. Eine flache Kurve entlang der Diagonalen deutet hingegen auf eine zufällige Klassifikation hin. Die AUC, also die Fläche unter der ROC-Kurve, gibt die allgemeine Klassifikationsleistung des Modells an. Sie berechnet sich als Integral der Kurve über alle Schwellenwerte:

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR})d(\text{FPR}).$$

Der AUC-Wert kann zwischen 0 und 1 liegen, wobei höhere Werte auf eine bessere Trennfähigkeit hinweisen. Ein Wert von 1 bedeutet perfekte Klassifikation, ein Wert von 0.5 entspricht einer rein zufälligen Vorhersage, und Werte unter 0.5 deuten darauf hin, dass das Modell schlechter als Zufall arbeitet. Falls dies der Fall ist, könnte eine Umkehrung der Klassenzuordnung oder eine Anpassung des Modells erforderlich sein. Die ROC-Analyse ist besonders hilfreich, wenn die Kosten für Fehlklassifikationen unterschiedlich gewichtet werden sollen. In praktischen Anwendungen wird oft ein optimaler Schwellenwert gesucht, der eine ausgewogene Sensitivität und Spezifität gewährleistet. Abhängig vom Anwendungsfall kann entweder eine hohe Sensitivität oder eine hohe Spezifität entscheidend sein. Durch die Kombination von ROC-Kurve und AUC lässt sich ein Modell objektiv bewerten, unabhängig von einer festen Entscheidungsgrenze. Diese Methode ermöglicht eine differenzierte Betrachtung der Vorhersagequalität und trägt zur Optimierung von Klassifikationsmodellen bei (vgl. Papp et al. 2022, S.214-216).

4 Statistische Auswertung

In diesem Kapitel wird der Datensatz zunächst einer deskriptiven Analyse unterzogen, um zentrale Verteilungen und Zusammenhänge der Variablen darzustellen. Dabei wird auf die Verwendung der Variable *Population_Density* verzichtet, da sie als Verhältnis von *Population* zu *Total_Area* berechnet wird und somit eine Abhängigkeit zwischen den Variablen erzeugt, die die Modellannahmen beeinträchtigen könnte. Um die Verteilungseigenschaften zu verbessern und eine bessere Anpassung an die Voraussetzungen des Modells zu erreichen, werden die Variablen *Total_Area* und *Population* logarithmiert. Im Anschluss daran werden die formulierten Fragestellungen mithilfe statistischer Methoden untersucht, wobei zentrale Variablen analysiert und die Ergebnisse im Hinblick auf ihre Bedeutung für das Wahlergebnis interpretiert werden.

4.1 Deskriptive Analyse

Die deskriptive Analyse der metrischen Variablen im Datensatz (Tabelle 3) zeigt deutliche Unterschiede in den Verteilungen. Die Gesamtfläche der Bundesstaaten variiert erheblich, von 0.070 bis 665.380 Tausend Quadratmeilen, mit einem Durchschnitt von 74.450 und einer rechtsschiefen Verteilung, die durch die hohe Standardabweichung von 96.930 bestätigt wird. Ähnlich zeigt die Einwohnerzahl eine starke Streuung, mit Werten zwischen 0.580 und 39.540 Millionen, einem Mittelwert von 6.500 und einem Median von 4.510, was ebenfalls auf eine rechtsschiefe Verteilung hindeutet. Das Medianalter hingegen ist relativ gleichmäßig verteilt, mit einem Mittelwert von 39.450 Jahren und einer Standardabweichung von 2.200. Die Geburtenrate weist eine moderate Streuung auf, mit einem Mittelwert von 52.020 und einem Median von 52.000, während der Human Development Index (HDI) zwischen 0.860 und 0.960 variiert und mit einem Mittelwert von 0.920 auf eine homogene hohe Lebensqualität hinweist. Die Arbeitslosenrate bewegt sich zwischen 0.026 und 0.055 (2.6 % bis 5.5 %) und zeigt eine geringe Streuung um einen Mittelwert von 3.9 %. Ebenso sind die Versicherungsraten hoch und konsistent, mit einem Mittelwert von 0.928 und einer Standardabweichung von 0.027. Die mediane Miete reicht von 0.850 bis 1.990 Tausend Dollar, wobei der Mittelwert von 1.300 und der Median von 1.240 auf regionale Unterschiede hinweist. Insgesamt zeigen die Ergebnisse, dass Variablen wie Bevölkerung, Gesamtfläche und Medianmiete erhebliche Unterschiede zwischen den Bundesstaaten aufweisen, während HDI, Arbeitslosenrate und Versicherungsrate homogener verteilt sind. Dies deutet darauf hin, dass bei der Analyse logarithmische Transformationen für stark streuende Variablen sinnvoll sein könnten, um die Verteilungen zu normalisieren und die Modellannahmen zu verbessern. Die in Abbildung 1 (Anhang S.16) dargestellte Säulen-

Tabelle 3: Deskriptive Statistiken der metrischen Variablen.

Variable	Mittelwert	Median	SD	Minimum	Maximum
Gesamtfläche (1000 sq mi)	74.450	56.270	96.930	0.070	665.380
Einwohnerzahl (Mio.)	6.500	4.510	7.410	0.580	39.540
Medianalter (Jahre)	39.450	39.300	2.200	32.300	44.900
Geburtenrate	52.020	52.000	5.500	39.000	66.000
HDI	0.920	0.920	0.020	0.860	0.960
Arbeitslosenrate	0.039	0.040	0.008	0.026	0.055
Versicherungsrate	0.928	0.935	0.027	0.836	0.974
Mediane Miete (1000\$)	1.300	1.240	0.310	0.850	1.990

grafik zeigt die Verteilung der von Harris und Trump gewonnenen Staaten bei der Wahl. Es wird deutlich, dass Trump mehr Staaten für sich entscheiden konnte als Harris. Diese

Beobachtung legt nahe, dass die geografische Verteilung der Unterstützung eine entscheidende Rolle bei den Wahlergebnissen gespielt hat. Eine detaillierte Untersuchung der zugrunde liegenden demografischen und sozioökonomischen Faktoren könnte dazu beitragen, die Unterschiede in der Unterstützung zwischen den beiden Kandidaten zu erklären. In Abbildung 2 (Anhang S.16) werden die Häufigkeitsverteilungen der zentralen metrischen Variablen grafisch dargestellt. Die Verteilungen der Gesamtfläche und der Einwohnerzahl zeigen eine starke rechtsschiefe Verteilung, was darauf hinweist, dass einige Staaten wesentlich größere Flächen oder Bevölkerungszahlen aufweisen als der Durchschnitt. Das Medianalter und die Geburtenrate sind symmetrisch verteilt, während der HDI (Human Development Index) und die Arbeitslosenrate eine leichtere Streuung um ihre Mittelwerte zeigen. Die Versicherungsrate und die mediane Miete weisen ebenfalls Verteilungen mit einer Konzentration um bestimmte Werte auf, was auf eine relative Homogenität dieser Variablen in den betrachteten Staaten schließen lässt.

4.2 Modellierung der Wahlergebnisse mit logistischer Regression

Die logistische Regression wird genutzt, um die Zielvariable „Kandidat“ zu modellieren, die eine binäre Klassifikation darstellt. Dabei wird „Harris“ mit 1 und „Trump“ mit 0 kodiert. Da es sich um ein Modell zur Vorhersage von Wahrscheinlichkeiten handelt, werden ausschließlich metrisch skalierte Prädiktoren berücksichtigt. Die Analyse basiert auf der Annahme, dass diese erklärenden Variablen unabhängig voneinander sind. Da einige Variablen, insbesondere die Gesamtfläche und die Einwohnerzahl, eine stark rechtsschiefe Verteilung aufweisen, wird eine logarithmische Transformation dieser Prädiktoren durchgeführt. Durch diese Anpassung wird die Verteilung symmetrischer, was die Modellanpassung verbessert und die Interpretation der Koeffizienten stabilisiert. Andere Prädiktoren, wie das Medianalter, die Geburtenrate, der HDI, die Arbeitslosenrate, die Versicherungsrate und die mediane Miete, zeigen keine ausgeprägte Schiefe und bleiben daher in ihrer ursprünglichen Form erhalten. Die Ergebnisse der logistischen Regression sind in Tabelle 4 (Anhang S.17) dargestellt. Die Analyse zeigt, welche Variablen den größten Einfluss auf die Wahlentscheidung haben und ob diese Effekte statistisch signifikant sind. Der berechnete AIC-Wert beträgt 34.198, was als Maß für die Modellgüte dient. Eine detaillierte Interpretation der Koeffizienten erfolgt in den folgenden Abschnitten.

4.3 Reduziertes Modell: Variablenselektion und Interpretation

Zur Optimierung des vollständigen Modells wird das Best-Subset-Selection-Verfahren eingesetzt, um eine reduzierte Modellstruktur mit den relevantesten Prädiktoren zu bestimmen. Dabei dient das Akaike-Informationskriterium (AIC) als Auswahlkriterium, um ein Modell mit möglichst wenigen, aber aussagekräftigen Variablen zu erhalten. Die Analyse zeigt, dass nicht alle ursprünglichen Variablen einen signifikanten Einfluss auf die Wahlentscheidung haben. Zur Bewertung der verbliebenen Prädiktoren wird der Wald-Test auf einem Signifikanzniveau von $\alpha = 0.05$ durchgeführt. Die Testergebnisse zeigen, dass insbesondere die Versicherungsrate und die mediane Miete signifikante Prädiktoren sind, da ihre p-Werte unter 0.05 liegen. Die Ergebnisse sind in Tabelle 5 (Anhang S.17) dargestellt. Zur Überprüfung der Schätzstabilität werden 95%-Wald-Konfidenzintervalle berechnet (Tabelle 6, Anhang S.17). Die Intervalle für die Versicherungsrate und die Miete schließen die Null nicht ein, was auf einen signifikanten Einfluss hinweist. Alle anderen Prädiktoren weisen Konfidenzintervalle auf, die die Null enthalten, wodurch kein eindeutiger Effekt nachgewiesen werden kann. Die Interpretation der geschätzten Koeffizienten zeigt, dass ein Anstieg der Versicherungsrate um 1 % die Wahrscheinlichkeit eines Wahlsiegs von Harris um den Faktor $\exp(1.404) \approx 4.07$ erhöht. Ebenso bedeutet ein Anstieg der medianen Miete um einen Dollar eine Erhöhung der Wahrscheinlichkeit für einen Wahlsieg von Harris um den Faktor $\exp(0.012) \approx 1.01$. Dies deutet darauf hin, dass höhere Versicherungsraten und Wohnkosten mit politischen Präferenzen korrelieren. Die Modellreduktion verbessert die Interpretierbarkeit der Ergebnisse, ohne die Vorhersagegenauigkeit wesentlich zu beeinträchtigen. Besonders die Versicherungsrate und die Mietpreise erweisen sich als Schlüsselfaktoren für die Wahlentscheidung.

4.4 Vergleich der Modellgüte mittels ROC-Kurven und AUC

Zur Bewertung der Modellgüte und Trennfähigkeit wird die Receiver Operating Characteristic (ROC)-Kurve verwendet, die die False-Positive-Rate gegen die True-Positive-Rate aufträgt. Eine 10-fache Kreuzvalidierung stellt sicher, dass die Ergebnisse robust sind und keine Überanpassung erfolgt. Die Ergebnisse sind in Abbildung 3 (Anhang S18) dargestellt. Das vollständige Modell wird durch eine gestrichelte blaue Linie, das reduzierte Modell durch eine durchgezogene rote Linie repräsentiert. Die Klassifikationsleistung wird durch die Fläche unter der Kurve (AUC) quantifiziert, wobei das vollständige Modell eine AUC von 0.862 und das reduzierte Modell eine AUC von 0.934 erzielt. Eine größere AUC deutet auf eine bessere Trennschärfe hin, sodass das reduzierte Modell präzisere Wahl-

ergebnisse liefert. Die verbesserte Performance des reduzierten Modells resultiert aus der Eliminierung irrelevanter Prädiktoren, wodurch das Modell kompakter und weniger anfällig für Overfitting wird. Während das vollständige Modell alle Variablen berücksichtigt, fokussiert sich das reduzierte Modell auf die relevanten Einflussgrößen, was Interpretierbarkeit und Generalisierbarkeit erhöht. Insgesamt zeigen die Ergebnisse, dass beide Modelle zuverlässig klassifizieren, jedoch das reduzierte Modell eine höhere Trennfähigkeit aufweist. Dies unterstreicht die Bedeutung einer gezielten Variablenselektion, um die Modellqualität zu optimieren und Verzerrungen durch irrelevante Variablen zu minimieren.

5 Zusammenfassung

Die Analyse untersucht die Einflussfaktoren auf die US-Präsidentchaftswahl 2024, bei der am 5. November das Electoral College bestimmt und am 17. Dezember Donald Trump als 47. Präsident der Vereinigten Staaten gewählt wurde. Der Datensatz umfasst 51 Beobachtungen und enthält demografische sowie sozioökonomische Merkmale der US-Bundesstaaten. Mittels logistischer Regression wurde geprüft, welche dieser Variablen signifikanten Einfluss auf das Wahlergebnis haben. Das vollständige Modell zeigte keine signifikanten Effekte, weshalb eine Variablenselektion mittels Best-Subset-Selection-Verfahren durchgeführt wurde. Das reduzierte Modell identifizierte die Versicherungsrate und die Medianmiete als entscheidende Einflussfaktoren für die Wahl von Kamala Harris. Zur Validierung wurden statistische Tests wie der Wald-Test und 95%-Konfidenzintervalle berechnet, die den signifikanten Einfluss dieser Variablen bestätigten. Die Modellbewertung erfolgte anhand von ROC-Kurven und der AUC, wobei das reduzierte Modell eine höhere Vorhersagegenauigkeit aufwies. Eine 10-fache Kreuzvalidierung stellte sicher, dass die Ergebnisse nicht von der Stichprobe abhingen. Trotz der Erkenntnisse bestehen methodische Einschränkungen. Die Annahme unabhängiger Bundesstaaten könnte problematisch sein, da politische und wirtschaftliche Wechselwirkungen existieren. Zudem fehlen potenziell relevante Einflussfaktoren wie ethnische Zusammensetzung oder frühere Wahlergebnisse. Zukünftige Forschungen sollten das Modell durch zusätzliche Variablen erweitern oder alternative Methoden testen. Langfristige Analysen könnten dabei helfen, Trends im Wahlverhalten zu identifizieren und politische Entscheidungen in den USA besser zu verstehen.

Literaturverzeichnis

- Agresti, A. (2007): An Introduction to Categorical Data Analysis. 2. Auflage. Wiley, New York.
- Behnke, J., Hrsg. (2015): Logistische Regressionsanalyse. Springer Fachmedien Wiesbaden, Wiesbaden. doi: 10.1007/978-3-658-05082-5.
- Calcagno, V. (2020): glmulti: Model Selection and Multimodel Inference Made Easy. R package version 1.0.8, URL: <https://CRAN.R-project.org/package=glmulti>.
- Fahrmeir, L., T. Kneib und S. Lang (2009): Regression: Modelle, Methoden und Anwendungen. Springer.
- Hosmer, D. W., S. Lemeshow und R. X. Sturdivant (2013): Applied logistic regression. John Wiley und Sons.
- Kuhn, M. (2008): Building Predictive Models in R Using the caret Package. Journal of Statistical Software, 28(5), 1–26. URL: <https://doi.org/10.18637/jss.v028.i05> .
- McLeod A, Xu C, Lai Y (2020): bestglm: Best Subset GLM and Regression Utilities. R package version 0.37.3, URL: <https://CRAN.R-project.org/package=bestglm>.
- Miller, A. (2024): leaps: Regression Subset Selection. R package version 3.2, URL: <https://CRAN.R-project.org/package=leaps>.
- Papp, S., W. Weidinger, K. Munro, B. Ortner, A. Cadonna, G. Langs, R. Licandro, M. Meir-Huber, D. Nikolić, Z. Toth, B. Vesela, R. Wazir und G. Zauner (2022): Handbuch Data Science und KI: Mit Machine Learning und Datenanalyse Wert aus Daten generieren. 2. Auflage. Hanser eLibrary. Hanser, München. doi: 10.3139/9783446472457 .
URL: <https://www.hanserelibrary.com/doi/book/10.3139/9783446472457>
- Pedersen, T. (2024): patchwork: The Composer of Plots. R package version 1.3.0, URL: <https://CRAN.R-project.org/package=patchwork>.
- Wickham, H. (2016): ggplot2: Elegant Graphics for Data Analysis. Springer-Verlag New York .
- Wickham H, Averick M, Bryan J, Chang W, McGowan LD, François R, Golemund G, Hayes A, Henry L, Hester J, Kuhn M, Pedersen TL, Miller E, Bache SM, Müller K, Ooms J, Robinson D, Seidel DP, Spinu V, Takahashi K, Vaughan D, Wilke C, Woo K, Yutani H (2019). “Welcome to the tidyverse.” Journal of Open Source

Software, *4*(43), 1686. doi:10.21105/joss.01686, URL: <https://doi.org/10.21105/joss.01686> .

- Xavier Robin, Natacha Turck, Alexandre Hainard, Natalia Tiberti, Frédérique Lisacek, Jean-Charles Sanchez and Markus Müller (2011): pROC: an open-source package for R and S+ to analyze and compare ROC curves. BMC Bioinformatics, 12, p. 77. DOI: 10.1186/1471-2105-12-77, URL: <http://www.biomedcentral.com/1471-2105/12/77/>.
- BPB (2024): <https://www.bpb.de/themen/nordamerika/usa/10672/wirtschaft/> (besucht am 29.01.2025)
- CDC/National Center for Health Statistics (2020): Life Expectancy at Birth by State. URL: https://www.cdc.gov/nchs/pressroom/sosmap/life_expectancy/life_expectancy.htm (besucht am 12.11.2024)
- Global Data Lab (2022): Subnational HDI (v8.1). URL: <https://globaldatalab.org/shdi/table/sh/USA/> (besucht am 12.11.2024)
- The Associated Press (2024): 2024 Presidential Election Results. URL: <https://apnews.com/projects/election-results-2024/?office=P> (besucht am 12.11.2024)
- U.S. Census Bureau (2010): State Area Measurements and Internal Point Coordinates. URL: <https://www.census.gov/geographies/reference-files/2010/geo/state-area.html> (besucht am 12.11.2024)
- U.S. Census Bureau (2020): Historical Population Density Data. URL: <https://www.census.gov/data/tables/time-series/dec/density-data-text.html> (besucht am 12.11.2024)
- U.S. Census Bureau, U.S. Department of Commerce (2023a): Age and Sex. URL: [https://data.census.gov/table/ACSST1Y2023.S0101?g=010XX00US,\\$0400000](https://data.census.gov/table/ACSST1Y2023.S0101?g=010XX00US,$0400000) (besucht am 12.11.2024)
- U.S. Census Bureau, U.S. Department of Commerce (2023b): Fertility. URL: [https://data.census.gov/table/ACSST1Y2023.S1301?g=010XX00US,\\$0400000](https://data.census.gov/table/ACSST1Y2023.S1301?g=010XX00US,$0400000) (besucht am 12.11.2024)
- U.S. Census Bureau, U.S. Department of Commerce (2023c): Selected Economic Characteristics. URL: <https://data.census.gov/table/>

ACSDP1Y2023.DP03?g= 010XX00US,\$0400000

(besucht am 12.11.2024)

- U.S. Census Bureau, U.S. Department of Commerce (2023d): Selected Housing Characteristics. URL: [https://data.census.gov/table/ACSDP1Y2023.DP04?g= 010XX00US,\\$0400000](https://data.census.gov/table/ACSDP1Y2023.DP04?g= 010XX00US,$0400000)
(besucht am 12.11.2024)
- R Core Team (2024): *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. URL: <https://www.R-project.org/>.

Anhang

A: Deskriptive Grafiken




Abbildung 1: Anzahl der von Harris und Trump gewonnenen Staaten.




Abbildung 2: Verteilung der verhältnisskalierten Variablen.

B: Tabellen

Tabelle 4: Ergebnisse der logistischen Regression.

Variable	$\hat{\beta}_j$	$\hat{\sigma}(\hat{\beta}_j)$	z-Wert	p-Wert
Intercept	-132.500	83.320	-1.590	0.112
Gesamtfläche	-1.060	1.495	-0.709	0.478
Einwohnerzahl	-1.667	1.071	-1.557	0.119
Medianalter	0.269	0.596	0.450	0.652
Geburtenrate	-0.053	0.277	-0.193	0.847
HDI	62.990	61.790	1.019	0.308
Arbeitslosenrate	2.392	1.733	1.381	0.167
Versicherungsrate	0.905	0.664	1.363	0.173
Mediane Miete	0.007	0.006	1.301	0.193

Tabelle 5: Ergebnisse des reduzierten Modells.

Variable	$\hat{\beta}_j$	$\hat{\sigma}(\hat{\beta}_j)$	z-Wert	p-Wert
Intercept	-143.100	52.500	-2.725	0.006
Einwohnerzahl	-1.672	0.919	-1.819	0.069
Medianalter	0.378	0.296	1.278	0.201
Arbeitslosenrate	1.818	1.274	1.427	0.153
Versicherungsrate	1.404	0.554	2.534	0.011
Mediane Miete	0.012	0.004	2.676	0.007

Tabelle 6: Wald-Konfidenzintervalle für die Regressionskoeffizienten.

Variable	2.5%	97.5%
Intercept	-245.970	-40.186
Einwohnerzahl	-3.474	0.129
Medianalter	-0.202	0.959
Arbeitslosenrate	-0.678	4.315
Versicherungsrate	0.318	2.490
Mediane Miete	0.003	0.020

C: ROC-Kurve




Abbildung 3: ROC-Kurven des vollständigen und reduzierten Modells.